A1：NumPy 全连接网络图像分类实验报告

1. 任务与完成范围

本实验使用 MNIST 手写数字数据集。核心计算全部使用 NumPy。实现范围包括前向传播、反向传播、参数更新和评估。Matplotlib 只负责绘图。项目未使用 PyTorch、TensorFlow 或 scikit-learn。

实验覆盖基础任务和 2 项附加题。附加题包含损失函数、正则化方法和优化算法的对照。线性分类器作为额外基线。原目录 `A1` 保持不变。

2. 数据与实验协议

MNIST 包含 60,000 张原始训练图像和 10,000 张测试图像。每张图像为 28×28 灰度图，标签为数字 0 至 9。数据说明见 MNIST 数据集文档。下载地址使用 Google 托管的 MNIST 文件。下载程序验证 4 个压缩文件的 MD5 摘要。MD5 用于识别数据文件，不用于安全认证。

训练集包含 50,000 张图像。验证集包含 10,000 张图像。测试集包含 10,000 张图像。训练集与验证集采用分层随机划分。划分种子为 2026，索引保存在 `results/split_indices.npz`。所有实验使用相同的划分。

像素值除以 255 后展平为 784 维向量。预处理不估计测试集统计量。

学习率搜索只使用训练集与验证集。每种优化器搜索 2 个预先设置的学习率。每个候选训练 3 轮，搜索种子为 42。正式实验使用种子 42, 43, 44。同一种子使用相同的初始化与批次排列。Dropout 使用独立随机数流。

每个正式实验训练 12 轮，批次大小为 128。程序按验证准确率保存最佳轮次。准确率相同时，程序选择硬标签交叉熵更小的轮次。最终配置取 3 个种子的平均验证准确率最大者。平均值相同时，程序取配置表中的首项。最终模型固定采用种子 42。

程序在 `selection.json` 中保存选择结果。程序随后加载测试集，评估所有已确定的模型。测试结果不参与调参、选轮次或选模型。

3. 模型与手写计算

多层感知机（MLP）的结构为 `784 → 128 → 64 → 10`。模型包含 109,386 个可训练参数。隐藏层使用修正线性单元（ReLU）。输出层产生 10 个未归一化分数。Softmax 将分数转换为类别概率。

隐藏层采用 He 初始化。输出层从均值为 0、方差为 `1 / fan_in` 的正态分布采样。偏置初始化为 0。

设某层输入为 A，权重为 W，偏置为 b。前向传播为 $Z = AW + b$。隐藏层输出为 $\max(0, Z)$。Softmax 先减去每行最大值，再计算指数。交叉熵通过对数求和指数形式计算。这两项处理用于避免数值溢出。

交叉熵为 $L = -\frac{1}{N}\sum_{i,k} q_{ik} \log p_{ik}$。输出梯度为 $\partial L/\partial Z = (P - Q)/N$。标签平滑使用 $q = (1-\alpha)y + \alpha/K$。本实验设置 $\alpha = 0.1$，$K = 10$。正确类别的目标值为 0.91，其余类别为 0.01。

均方误差（MSE）定义为 $L = \frac{1}{2N}\sum_{i,k}(p_{ik} - q_{ik})^2$。MSE 先对概率求导，再乘 Softmax 的雅可比矩阵。代码使用雅可比矩阵与向量的乘积，避免构造完整矩阵。

若上游梯度为 G，权重梯度为 $A^T G$。偏置梯度为 $\sum_i G_i$，输入梯度为 GW^T。ReLU 反向传播保留正输入位置的梯度。各层按逆序计算梯度。全部梯度计算完成后，优化器更新参数。

L2 惩罚为 $\lambda \sum_l \|W_l\|_F^2/2$。权重梯度增加 λW_l，偏置不受惩罚。本实验设置 $\lambda = 10^{-4}$。Dropout 的丢弃概率为 0.2。训练时保留的激活值除以 0.8。评估时关闭 Dropout。

4. 对照设计与学习率搜索

随机梯度下降（SGD）按 $\theta \leftarrow \theta - \eta g$ 更新参数。本实验的 SGD 每次使用一个小批次。Momentum 设置动量系数为 0.9。Momentum 累积方向信息后更新参数。

Adagrad 累积各参数的梯度平方。Adam 维护梯度的一阶矩和二阶矩。Adamax 使用梯度绝对值的衰减最大值。

Adam 与 Adamax 均校正一阶矩的初始偏差。Adam 还校正二阶矩的初始偏差。两者使用 $\beta_1 = 0.9$、$\beta_2 = 0.999$。稳定项 $\epsilon = 10^{-8}$。更新公式位于 `src/a1_numpy/optim.py`。

搜索实验	学习率	最佳验证准确率（%）
tune_sgd_0.03	0.03	92.03
tune_sgd_0.1	0.1	94.43
tune_momentum_0.01	0.01	94.93
tune_momentum_0.03	0.03	96.70
tune_adagrad_0.01	0.01	95.89
tune_adagrad_0.03	0.03	96.59
tune_adam_0.0003	0.0003	94.33
tune_adam_0.001	0.001	96.63
tune_adamax_0.001	0.001	94.51
tune_adamax_0.003	0.003	96.51

选定学习率为：`{"sgd": 0.1, "momentum": 0.03, "adagrad": 0.03, "adam": 0.001, "adamax": 0.003}`。

优化器对照统一使用交叉熵和相同网络。损失函数与正则化对照统一使用 Adam。这些对照沿用交叉熵基线选定的 Adam 学习率。每个对照只替换损失函数或一项正则化设置。线性基线删除全部隐藏层，直接计算 Softmax 分类。线性基线也沿用 Adam 的学习率。

5. 正式实验结果

表中准确率采用百分比。“±”后的数值为 3 个种子的样本标准差。宏平均 F1 也乘以 100。时间是单次运行的平均耗时，单位为秒。时间包含训练、验证、训练集评估和模型保存。时间不能代表优化器更新公式的独立耗时。

实验	训练准确率（%）	验证准确率（%）	测试准确率（%）	测试宏平均 F1	平均耗时（秒）
`ce_sgd`	98.80 ± 0.03	97.13 ± 0.03	97.39 ± 0.12	97.37	2.5
`ce_momentum`	99.67 ± 0.08	97.64 ± 0.07	97.79 ± 0.04	97.77	2.7
`ce_adagrad`	99.60 ± 0.08	97.54 ± 0.03	97.64 ± 0.13	97.62	3.0
`ce_adam`	99.46 ± 0.13	97.55 ± 0.12	97.72 ± 0.13	97.70	3.7
`ce_adamax`	99.45 ± 0.27	97.61 ± 0.14	97.70 ± 0.10	97.68	3.4
`mse_adam`	99.24 ± 0.23	97.48 ± 0.16	97.66 ± 0.28	97.64	3.7
`smooth_adam`	99.82 ± 0.01	98.04 ± 0.13	98.02 ± 0.12	98.01	3.8
`l2_adam`	99.50 ± 0.17	97.68 ± 0.12	97.86 ± 0.17	97.85	3.6
`dropout_adam`	99.24 ± 0.10	97.68 ± 0.12	97.77 ± 0.05	97.76	4.5
`linear_adam`	92.96 ± 0.03	92.02 ± 0.05	92.57 ± 0.07	92.45	1.1

所有训练准确率均来自所选轮次的完整训练集评估。评估使用固定参数，并关闭 Dropout。每轮在线损失另存为 `online_objective`。评估按样本数加权，正确计入末尾不足一个批次的数据。

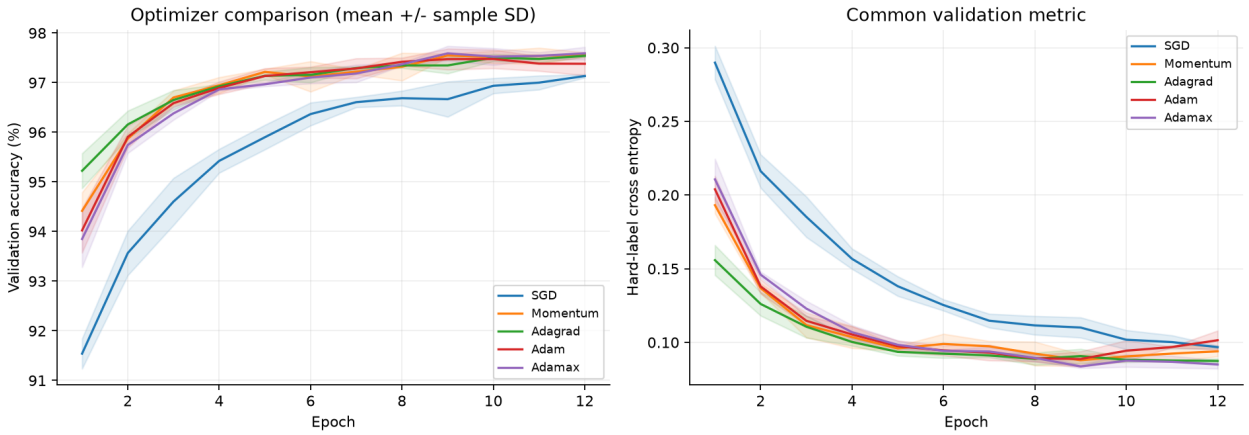


图 1: 优化器对照

优化器组中，ce_adagrad 的首轮平均验证准确率最高。按最佳轮次汇总，ce_momentum 的平均验证准确率最高。不同算法的学习率来自相同规模的搜索。这些结果仅适用于当前网络、候选学习率与训练轮数。3 轮搜索偏向收敛较早的配置，可能漏掉后期表现更好的学习率。

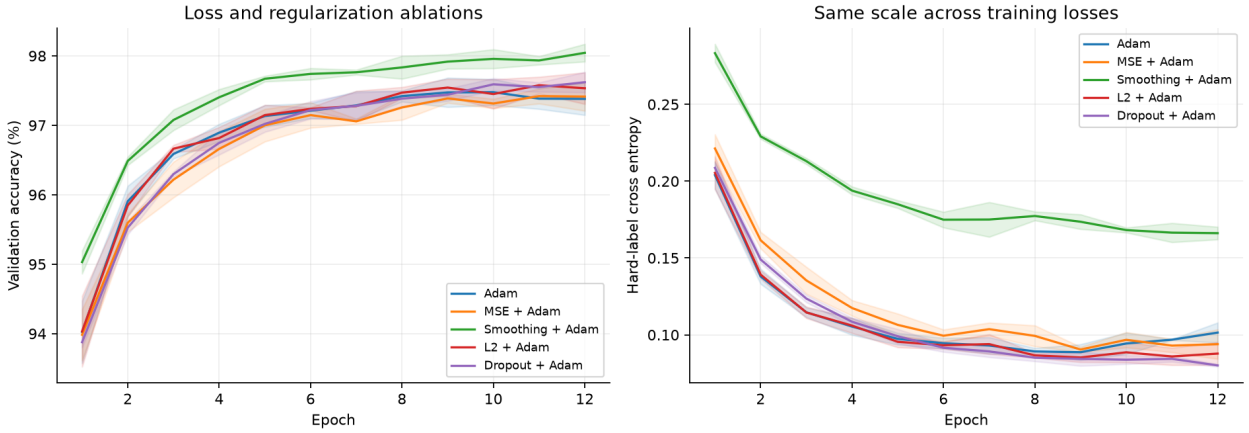


图 2: 损失函数与正则化对照

以 ce_adam 为基线，结果变化如下。

- mse_adam：验证准确率变化 -0.07 个百分点。测试准确率变化 -0.06 个百分点。
- smooth_adam：验证准确率变化 +0.49 个百分点。测试准确率变化 +0.30 个百分点。
- l2_adam：验证准确率变化 +0.13 个百分点。测试准确率变化 +0.14 个百分点。
- dropout_adam：验证准确率变化 +0.13 个百分点。测试准确率变化 +0.05 个百分点。

实验	训练与验证准确率差值（百分点）	测试交叉熵	平均最高类别概率（%）
ce_adam	1.90	0.0773	98.31
mse_adam	1.76	0.0839	98.10
smooth_adam	1.78	0.1636	87.82
l2_adam	1.82	0.0732	98.29
dropout_adam	1.56	0.0786	98.36

标签平滑提高了本次实验的平均验证准确率。平均最大预测概率也随标签平滑降低。软标签使模型减弱对单个类别的确定性。硬标签交叉熵却有所升高，说明准确率与概率损失不一定同步改善。平均最大概率不能单独证明概率校准得到改善。

Dropout 缩小了训练与验证准确率的差距。L2 也缩小了差距，并提高了平均测试准确率。这些现象与限制模型拟合能力的作用一致。MSE 的平均准确率低于交叉熵基线。MSE 的输出梯度还包含 Softmax 的雅可比矩阵。这个因子可能减小饱和区域的梯度。

交叉熵和 MSE 的原始损失尺度不同。报告使用硬标签交叉熵作为共同评价指标。标签平滑的目标分布不同，也采用这个共同指标。正则化方法不保证提高当前数据集的准确率。具体判断应结合验证准确率、训练差距和随机种子波动。单一强度的对照不能证明某种正则化方法始终有效或无效。

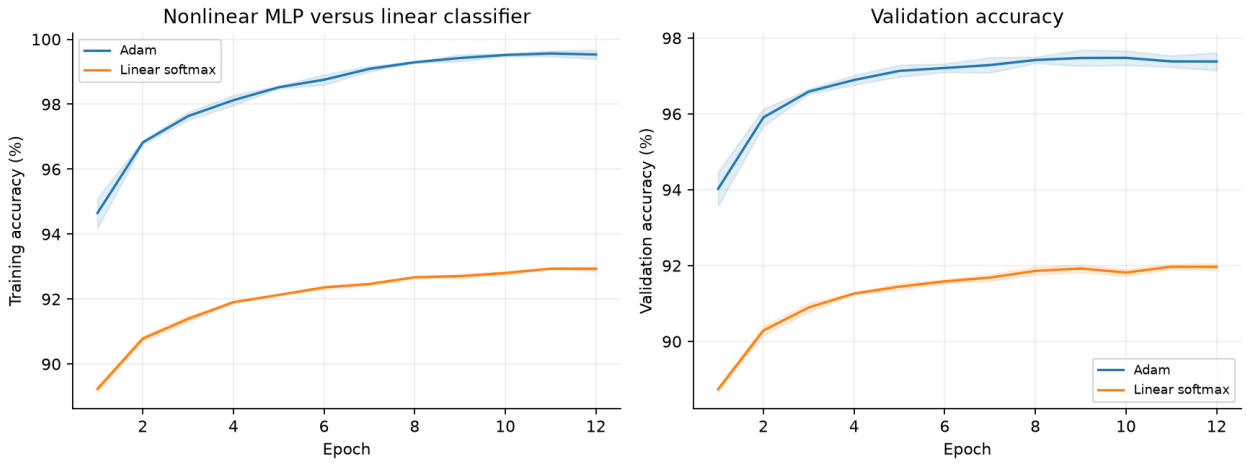


图 3: 分类器对照

交叉熵 MLP 的平均验证准确率为 97.55%。在线性基线上，平均验证准确率为 92.02%。差值为 5.53 个百分点。这项对照统一采用交叉熵和 Adam。线性基线使用线性决策边界。MLP 通过隐藏层学习非线性特征。

这项对照同时改变了参数量，不能单独量化非线性的贡献。

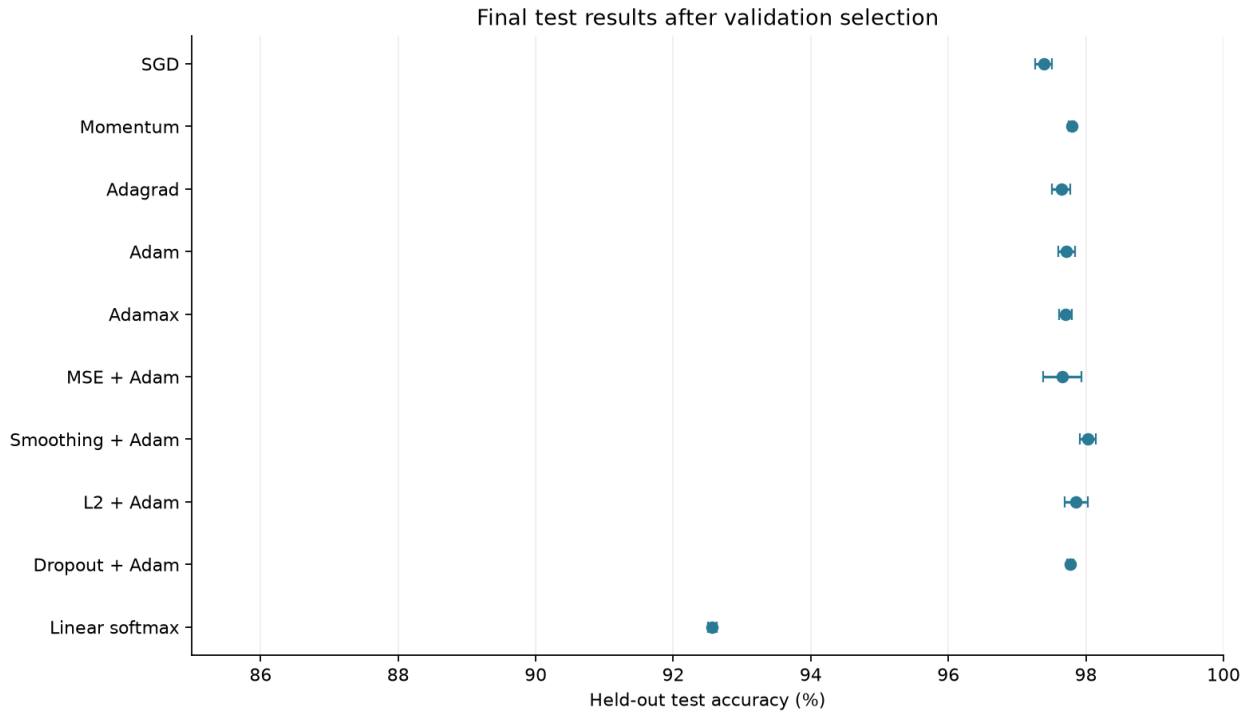


图 4: 最终测试准确率

最终选择为 `smooth_adam`，依据是平均验证准确率。最终单模型来自种子 42 的第 12 轮。最终单模型的测试准确率为 **98.15%**。测试宏平均 F1 为 **98.13%**。最终模型文件为 `results/best_model.npz`。

6. 类别评估与错误分析

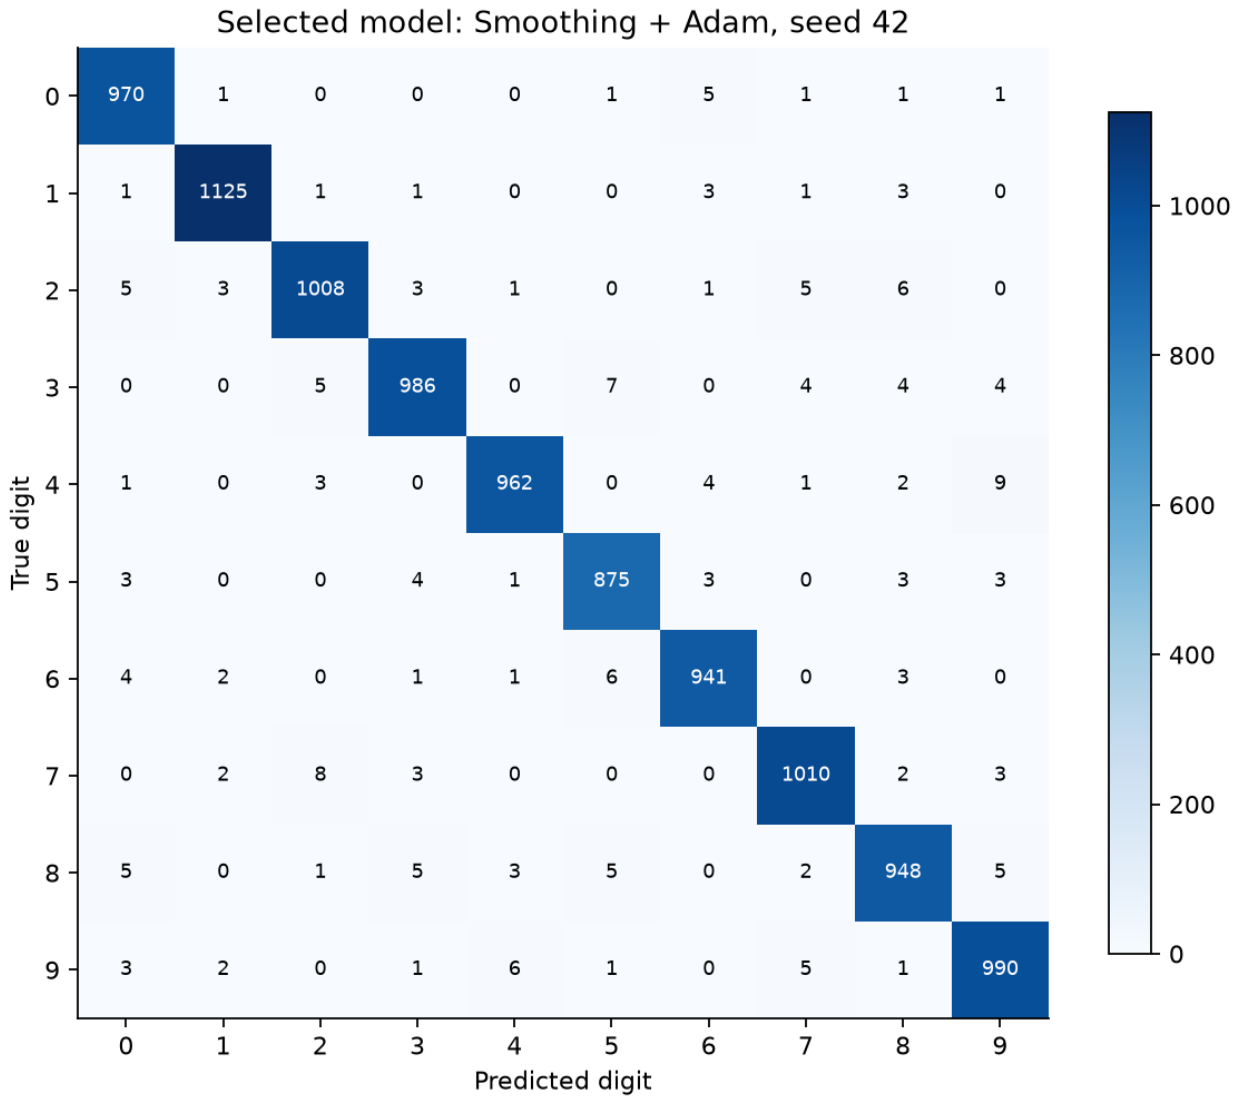


图 5: 混淆矩阵

混淆矩阵的行是真实标签，列是预测标签。最终单模型中，数量最多的 3 类误判为：4→9（9 张）、7→2（8 张）、3→5（7 张）。矩阵揭示易混类别，不能单独解释每张图像的误判原因。

数字	精确率（%）	召回率（%）	F1（%）	样本数
0	97.78	98.98	98.38	980
1	99.12	99.12	99.12	1135
2	98.25	97.67	97.96	1032
3	98.21	97.62	97.91	1010
4	98.77	97.96	98.36	982
5	97.77	98.09	97.93	892
6	98.33	98.23	98.28	958
7	98.15	98.25	98.20	1028
8	97.43	97.33	97.38	974
9	97.54	98.12	97.83	1009

7. 正确性验证与复现

tests/test_core.py 包含 18 项自动测试。数值梯度测试使用中心差分和双精度浮点数。测试覆盖交叉熵、MSE、标签平滑、L2 和 Dropout。Dropout 梯度测试固定掩码，排除随机噪声。测试还覆盖 5 种优化器的两步更新。

其余测试验证数据划分、模型保存恢复和指标计算。合成数据测试验证模型是否能学会分类。依赖检查验证源码未导入深度学习框架。

交付核对覆盖全部 30 次正式实验。核对内容包含最佳轮次、模型加载和混淆矩阵。最终模型按原配置重新训练后，所有参数逐项一致。命令行推理也通过 8 张训练图像的核对。核对记录见 results/verification.json。

Python 版本：3.11.14。NumPy 版本：2.4.6。环境基于 uv 管理的 Python 3.11。依赖版本记录在 uv.lock。

核心源码摘要记录在 results/manifest.json。正式训练累计耗时为 95.7 秒。学习率搜索耗时另见 results/tuning.csv。复现命令见 README.md。

8. 限制与结论

本实验使用一个固定数据划分和 3 个训练种子。标准差描述初始化与批次顺序带来的波动。重新划分数据带来的不确定性不在标准差的描述范围内。本实验未实施统计显著性检验。

学习率候选只有 2 个，搜索轮数为 3。损失函数和正则化对照未单独重新搜索学习率。结论不代表各方法经过充分调参后的最优性能。不同硬件和数值库可能产生数值及耗时差异。

本实验完成 NumPy 全连接图像分类流程。基础实现包含手写前向传播、反向传播和评估。对照实验覆盖两类损失、三种正则化和五种优化器。所有报告数值均来自保存的实验结果。