目录

A1：NumPy 全连接网络图像分类实验报告 **2**
1. 任务与完成范围 . . . 2
2. 数据与实验协议 . . . 2
3. 模型与手写计算 . . . 2
4. 对照设计与学习率搜索 . . . 3
5. 正式实验结果 . . . 3
6. 类别评估与错误分析 . . . 6
7. 正确性验证与复现 . . . 7
8. 实验结论 . . . 7
附录 A. 完整参数与计算定义 . . . 8
附录 B. 学习率搜索与逐次结果 . . . 10
附录 C. 各配置完整训练曲线与混淆矩阵 . . . 13
附录 D. 全部模型的逐类指标 . . . 24
附录 E. 实现流程、验证记录与复现 . . . 28

A1：NumPy 全连接网络图像分类实验报告

1. 任务与完成范围

本实验使用 MNIST 手写数字数据集。核心计算全部使用 NumPy。实现范围包括前向传播、反向传播、参数更新和评估。Matplotlib 只负责绘图。梯度计算由手写的求导公式完成。

实验覆盖基础任务和 2 项附加题。附加题包含损失函数、正则化方法和优化算法的对照。线性分类器作为额外基线。

正文说明数据划分、计算方法和实验结论。附录 A 列出完整参数和计算公式。附录 B 汇总学习率搜索和 30 次运行的明细。附录 C 展示逐轮曲线和全部模型的混淆矩阵。附录 D 列出逐类指标，附录 E 给出实现流程与复现步骤。

作业要求	实验内容	报告位置
基础题：NumPy 全连接分类器	手写前向传播、反向传播、训练与评估	第 2、3、6、7 节，附录 A、E
数据划分与调参	固定训练、验证、测试划分及学习率搜索	第 2、4 节，附录 B
损失与正则化附加题	交叉熵、MSE、标签平滑、L2、Dropout	第 5 节，附录 C、D
优化算法附加题	SGD、Momentum、Adagrad、Adam、Adamax	第 4、5 节，附录 A、B、C

2. 数据与实验协议

MNIST 包含 60,000 张原始训练图像和 10,000 张测试图像。每张图像为 28×28 灰度图，标签为数字 0 至 9。数据说明见 MNIST 数据集文档。下载地址使用 Google 托管的 MNIST 文件。下载程序验证 4 个压缩文件的 MD5 摘要。MD5 摘要用于验证下载文件与数据源的一致性。

训练集包含 50,000 张图像。验证集包含 10,000 张图像。测试集包含 10,000 张图像。训练集与验证集采用分层随机划分。划分种子为 2026，索引保存在 `results/split_indices.npz`。所有实验使用相同的划分。

像素值除以 255 后展平为 784 维向量。训练集、验证集与测试集统一使用固定的像素缩放系数。

学习率搜索只使用训练集与验证集。每种优化器搜索 2 个预先设置的学习率。每个候选训练 3 轮，搜索种子为 42。正式实验使用种子 42, 43, 44。同一种子使用相同的初始化与批次排列。Dropout 使用独立随机数流。

每个正式实验训练 12 轮，批次大小为 128。程序按验证准确率保存最佳轮次。准确率相同时，程序选择硬标签交叉熵更小的轮次。最终配置取 3 个种子的平均验证准确率最大者。平均值相同时，程序取配置表中的首项。最终模型固定采用种子 42。

程序在 `selection.json` 中保存选择结果。程序随后加载测试集，评估所有已确定的模型。学习率、最佳轮次和最终配置均依据验证集结果确定。

3. 模型与手写计算

多层感知机（MLP）的结构为 `784 → 128 → 64 → 10`。模型包含 109,386 个可训练参数。隐藏层使用修正线性单元（ReLU）。输出层产生 10 个类别分数。Softmax 将分数转换为类别概率。

隐藏层采用 He 初始化。输出层从均值为 0、方差为 `1 / fan_in` 的正态分布采样。偏置初始化为 0。

设某层输入为 A，权重为 W，偏置为 b。前向传播为 $Z = AW + b$。隐藏层输出为 $\max(0, Z)$。Softmax 先减去每行最大值，再计算指数。交叉熵通过对数求和指数形式计算。这两项处理用于避免数值溢出。

交叉熵为 $L = -\frac{1}{N}\sum_{i,k} q_{ik} \log p_{ik}$。输出梯度为 $\partial L/\partial Z = (P - Q)/N$。标签平滑使用 $q = (1-\alpha)y + \alpha/K$。本实验设置 $\alpha = 0.1$，$K = 10$。正确类别的目标值为 0.91，其余类别为 0.01。

均方误差（MSE）定义为 $L = \frac{1}{2N}\sum_{i,k}(p_{ik} - q_{ik})^2$。MSE 先对概率求导，再乘 Softmax 的雅可比矩阵。代码使用雅可比矩阵与向量的乘积，避免构造完整矩阵。

若上游梯度为 G，权重梯度为 A^TG。偏置梯度为 $\sum_i G_i$，输入梯度为 GW^T。ReLU 反向传播保留正输入位置的梯度。各层按逆序计算梯度。全部梯度计算完成后，优化器更新参数。

L2 惩罚为 $\lambda \sum_l \|W_l\|_F^2/2$。权重梯度增加 λW_l，偏置梯度来自数据损失。本实验设置 $\lambda = 10^{-4}$。Dropout 的丢弃概率为 0.2。训练时保留的激活值除以 0.8。评估时关闭 Dropout。

4. 对照设计与学习率搜索

随机梯度下降（SGD）按 $\theta \leftarrow \theta - \eta g$ 更新参数。本实验的 SGD 每次使用一个小批次。Momentum 设置动量系数为 0.9。Momentum 累积方向信息后更新参数。

Adagrad 累积各参数的梯度平方。Adam 维护梯度的一阶矩和二阶矩。Adamax 使用梯度绝对值的衰减最大值。

Adam 与 Adamax 均校正一阶矩的初始偏差。Adam 还校正二阶矩的初始偏差。两者使用 $\beta_1 = 0.9$、$\beta_2 = 0.999$。稳定项 $\epsilon = 10^{-8}$。更新公式位于 `src/a1_numpy/optim.py`。

搜索实验	学习率	最佳验证准确率（%）
tune_sgd_0.03	0.03	92.03
tune_sgd_0.1	0.1	94.43
tune_momentum_0.01	0.01	94.93
tune_momentum_0.03	0.03	96.70
tune_adagrad_0.01	0.01	95.89
tune_adagrad_0.03	0.03	96.59
tune_adam_0.0003	0.0003	94.33
tune_adam_0.001	0.001	96.63
tune_adamax_0.001	0.001	94.51
tune_adamax_0.003	0.003	96.51

选定学习率为：`{"sgd": 0.1, "momentum": 0.03, "adagrad": 0.03, "adam": 0.001, "adamax": 0.003}`。

优化器对照统一使用交叉熵和相同网络。损失函数与正则化对照统一使用 Adam。这些对照沿用交叉熵基线选定的 Adam 学习率。每个对照只替换损失函数或一项正则化设置。线性基线删除全部隐藏层，直接计算 Softmax 分类。线性基线也沿用 Adam 的学习率。

5. 正式实验结果

表中准确率采用百分比。“±”后的数值为 3 个种子的样本标准差。宏平均 F1 也乘以 100。时间是单次运行的平均耗时，单位为秒。时间包含训练、验证、训练集评估和模型保存。该时间衡量一次完整训练实验的运行开销。

实验	训练准确率（%）	验证准确率（%）	测试准确率（%）	测试宏平均 F1	平均耗时（秒）
`ce_sgd`	98.80 ± 0.03	97.13 ± 0.03	97.39 ± 0.12	97.37	2.5
`ce_momentum`	99.67 ± 0.08	97.64 ± 0.07	97.79 ± 0.04	97.77	2.7
`ce_adagrad`	99.60 ± 0.08	97.54 ± 0.03	97.64 ± 0.13	97.62	3.0
`ce_adam`	99.46 ± 0.13	97.55 ± 0.12	97.72 ± 0.13	97.70	3.7
`ce_adamax`	99.45 ± 0.27	97.61 ± 0.14	97.70 ± 0.10	97.68	3.4
`mse_adam`	99.24 ± 0.23	97.48 ± 0.16	97.66 ± 0.28	97.64	3.7
`smooth_adam`	99.82 ± 0.01	98.04 ± 0.13	98.02 ± 0.12	98.01	3.8
`l2_adam`	99.50 ± 0.17	97.68 ± 0.12	97.86 ± 0.17	97.85	3.6
`dropout_adam`	99.24 ± 0.10	97.68 ± 0.12	97.77 ± 0.05	97.76	4.5
`linear_adam`	92.96 ± 0.03	92.02 ± 0.05	92.57 ± 0.07	92.45	1.1

所有训练准确率均来自所选轮次的完整训练集评估。评估使用固定参数，并关闭 Dropout。每轮在线损失另存为 `online_objective`。评估按样本数加权，末尾批次按实际样本数计入。

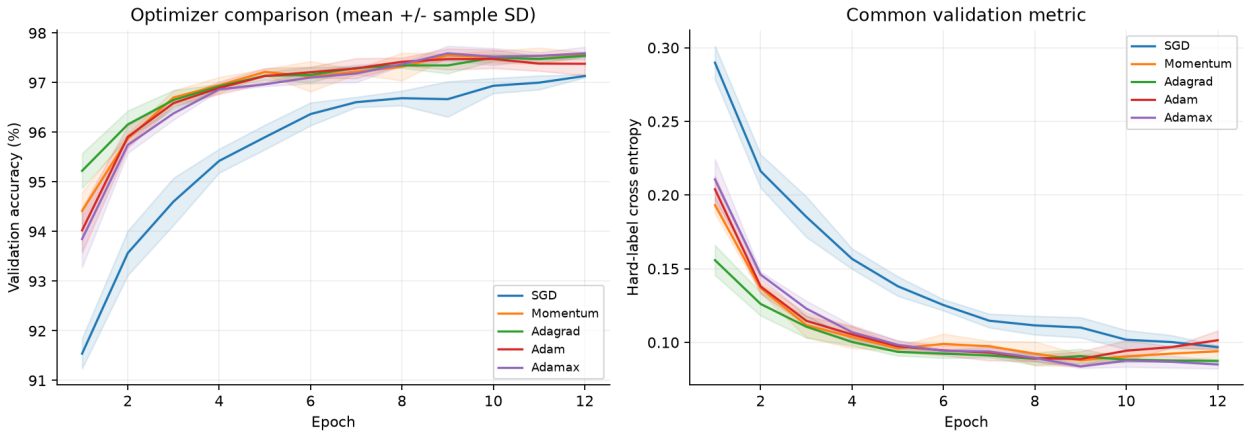


图 1: 优化器对照

优化器组中，ce_adagrad 的首轮平均验证准确率最高。按最佳轮次汇总，ce_momentum 的平均验证准确率最高。不同算法的学习率来自相同规模的搜索。这组结果来自相同网络结构和固定训练轮数的对照实验。学习率选择依据各候选在前 3 轮中的最佳验证准确率。

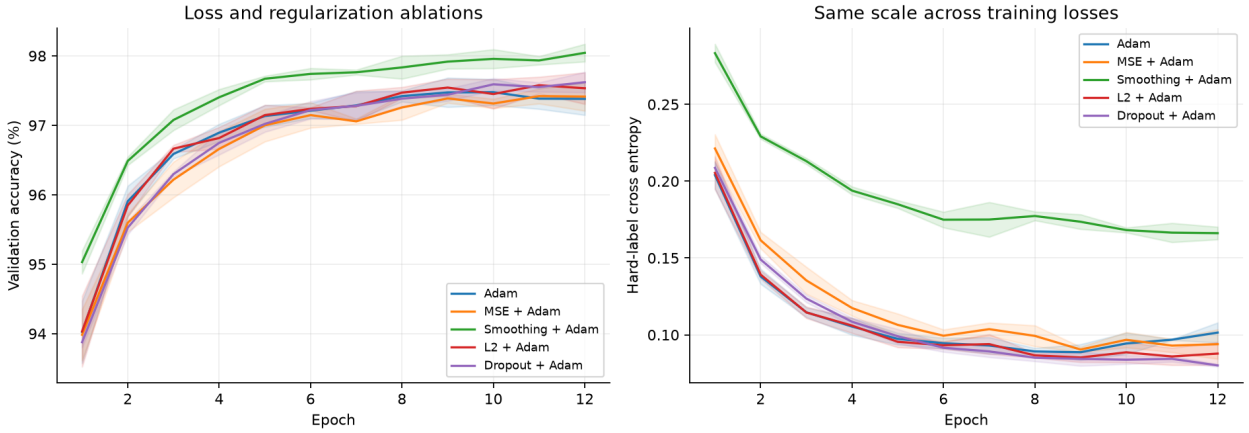


图 2: 损失函数与正则化对照

以 ce_adam 为基线，结果变化如下。

- mse_adam：验证准确率变化 -0.07 个百分点。测试准确率变化 -0.06 个百分点。
- smooth_adam：验证准确率变化 +0.49 个百分点。测试准确率变化 +0.30 个百分点。
- l2_adam：验证准确率变化 +0.13 个百分点。测试准确率变化 +0.14 个百分点。
- dropout_adam：验证准确率变化 +0.13 个百分点。测试准确率变化 +0.05 个百分点。

实验	训练与验证准确率差值（百分点）	测试交叉熵	平均最高类别概率（%）
ce_adam	1.90	0.0773	98.31
mse_adam	1.76	0.0839	98.10
smooth_adam	1.78	0.1636	87.82
l2_adam	1.82	0.0732	98.29
dropout_adam	1.56	0.0786	98.36

标签平滑提高了本次实验的平均验证准确率。平均最大预测概率也随标签平滑降低。软标签使模型减弱对单个类别的确定性。硬标签交叉熵同时升高，呈现出准确率提高、概率损失增大的结果。平均最大预测概率描述模型对预测类别的置信程度。

Dropout 缩小了训练与验证准确率的差距。L2 也缩小了差距，并提高了平均测试准确率。这些现象与限制模型拟合能力的作用一致。MSE 的平均准确率低于交叉熵基线。MSE 的输出梯度还包含 Softmax 的雅可比矩阵。这个因子可能减小饱和区域的梯度。

交叉熵和 MSE 的原始损失尺度不同。报告使用硬标签交叉熵作为共同评价指标。标签平滑的目标分布不同，也采用这个共同指标。本实验在预设强度下评估三种正则化方法。分析结合验证准确率、训练差距和随机种子波动。标签平滑、L2 和 Dropout 的结果分别对应各自的固定参数设置。

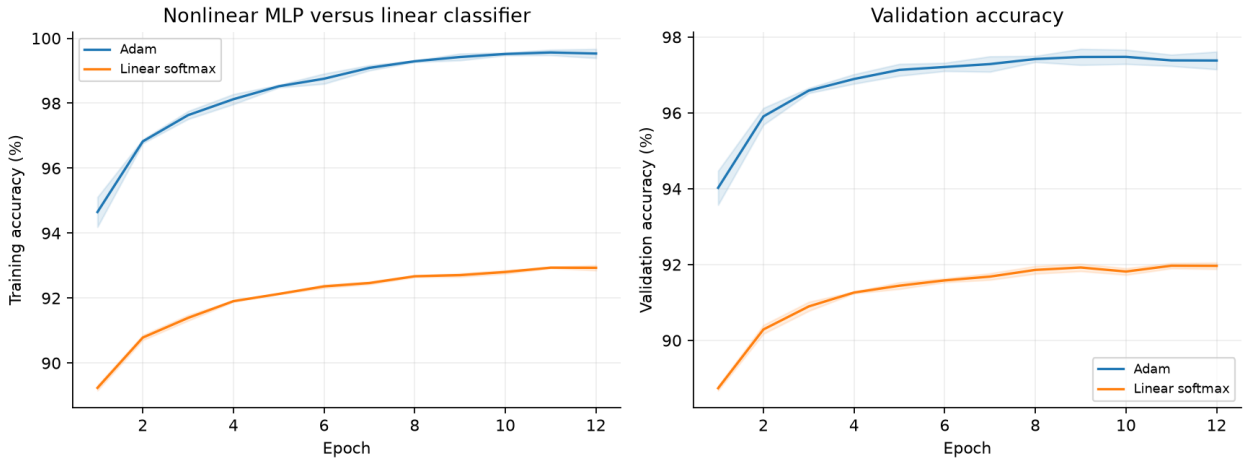


图 3: 分类器对照

交叉熵 MLP 的平均验证准确率为 97.55%。在线性基线上，平均验证准确率为 92.02%。差值为 5.53 个百分点。这项对照统一采用交叉熵和 Adam。线性基线使用线性决策边界。MLP 通过隐藏层学习非线性特征。

这项对照展示了网络结构与参数量共同变化时的分类性能差异。

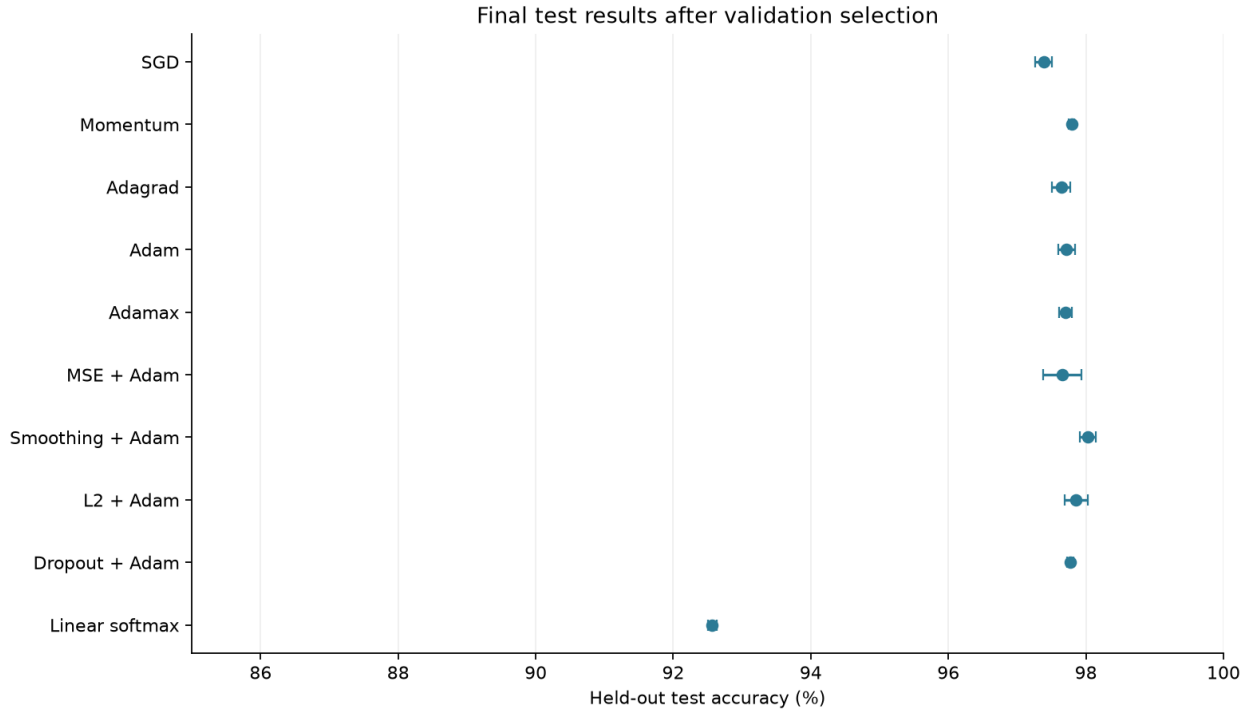


图 4: 最终测试准确率

最终选择为 `smooth_adam`，依据是平均验证准确率。最终单模型来自种子 42 的第 12 轮。最终单模型的测试准确率为 **98.15%**。测试宏平均 F1 为 **98.13%**。最终模型文件为 `results/best_model.npz`。

6. 类别评估与错误分析

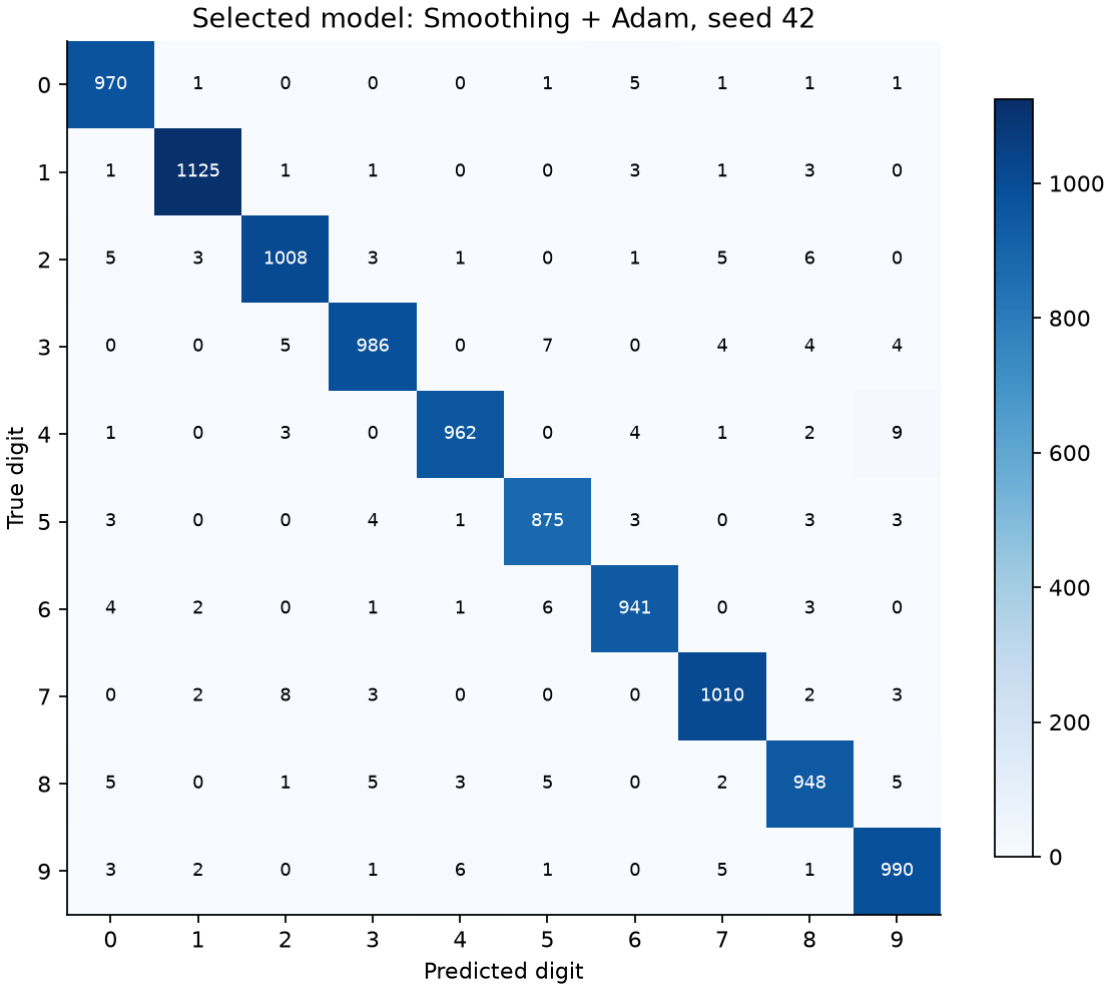


图 5: 混淆矩阵

混淆矩阵的行是真实标签，列是预测标签。最终单模型中，数量最多的 3 类误判为：4→9（9 张）、7→2（8 张）、3→5（7 张）。混淆矩阵统计各真实类别的预测分布，显示模型容易混淆的数字组合。

数字	精确率（%）	召回率（%）	F1（%）	样本数
0	97.78	98.98	98.38	980
1	99.12	99.12	99.12	1135
2	98.25	97.67	97.96	1032
3	98.21	97.62	97.91	1010
4	98.77	97.96	98.36	982
5	97.77	98.09	97.93	892
6	98.33	98.23	98.28	958
7	98.15	98.25	98.20	1028
8	97.43	97.33	97.38	974
9	97.54	98.12	97.83	1009

7. 正确性验证与复现

tests/test_core.py 包含 18 项自动测试。数值梯度测试使用中心差分和双精度浮点数。测试覆盖交叉熵、MSE、标签平滑、L2 和 Dropout。Dropout 梯度测试固定掩码，排除随机噪声。测试还覆盖 5 种优化器的两步更新。

其余测试验证数据划分、模型保存恢复和指标计算。合成数据测试验证模型是否能学会分类。依赖检查核对核心计算所用的 NumPy 实现。

结果核对覆盖全部 30 次正式实验。核对内容包含最佳轮次、模型加载和混淆矩阵。最终模型按原配置重新训练后，所有参数逐项一致。命令行推理也通过 8 张训练图像的核对。核对记录见 results/verification.json。

Python 版本：3.11.14。NumPy 版本：2.4.6。环境基于 uv 管理的 Python 3.11。依赖版本记录在 uv.lock。

核心源码摘要记录在 results/manifest.json。正式训练累计耗时为 95.7 秒。学习率搜索耗时列于附录 B.2。复现命令列于附录 E.3。

8. 实验结论

本实验使用一个固定数据划分和 3 个训练种子。标准差描述初始化与批次顺序带来的波动。均值和样本标准差汇总相同数据划分下的 3 次运行结果。

每种优化器搜索 2 个学习率候选，每个候选训练 3 轮。损失函数与正则化对照统一使用 Adam 基线选定的学习率。实验结果对应报告列出的网络结构、训练轮数和参数设置。运行环境及依赖版本记录在实验清单中。

本实验完成 NumPy 全连接图像分类流程。基础实现包含手写前向传播、反向传播和评估。对照实验覆盖两类损失、三种正则化和五种优化器。所有报告数值均来自保存的实验结果。

附录 A. 完整参数与计算定义

A.1 实验配置

所有配置使用 784 维输入和 10 维输出。隐藏层列按前向传播顺序列出宽度。训练参数采用单精度浮点数，梯度检查采用双精度浮点数。所有正式配置使用种子 42、43、44，各训练 12 轮。批次大小为 128，评估批次大小为 1,024。

配置	隐藏层	学习率	损失函数	平滑系数	L2 系数	丢弃概率
`ce_sgd`	128/64	0.1	cross_entropy	0	0	0
`ce_momentum`	128/64	0.03	cross_entropy	0	0	0
`ce_adagrad`	128/64	0.03	cross_entropy	0	0	0
`ce_adam`	128/64	0.001	cross_entropy	0	0	0
`ce_adamax`	128/64	0.003	cross_entropy	0	0	0
`mse_adam`	128/64	0.001	mse	0	0	0
`smooth_adam`	128/64	0.001	cross_entropy	0.1	0	0
`l2_adam`	128/64	0.001	cross_entropy	0	0.0001	0
`dropout_adam`	128/64	0.001	cross_entropy	0	0	0.2
`linear_adam`	线性层	0.001	cross_entropy	0	0	0

`cross_entropy` 表示交叉熵，`mse` 表示概率上的均方误差。配置名末尾标明优化器。MLP 的三层参数量分别为 100,480、8,256 和 650。线性分类器包含 7,850 个参数。每轮训练更新 391 次参数，末尾批次包含 80 个样本。12 轮训练共更新 4,692 次参数。

A.2 优化器更新公式

设第 t 次更新的梯度为 g_t，学习率为 η。下列乘法、平方和除法均按参数元素计算。动量与累积量初始值均为 0。各优化器在单次实验内保持学习率固定。

SGD 使用当前小批次的梯度：

$$\theta_t = \theta_{t-1} - \eta g_t.$$

Momentum 累积历史梯度，动量系数 $\mu = 0.9$：

$$v_t = \mu v_{t-1} + g_t, \qquad \theta_t = \theta_{t-1} - \eta v_t.$$

Adagrad 按历史梯度平方和调整步长：

$$s_t = s_{t-1} + g_t^2, \qquad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{s_t} + \epsilon}.$$

Adam 使用指数移动平均与偏差校正：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t,$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2,$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \qquad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \qquad \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}.$$

Adamax 沿用 Adam 的一阶矩 m_t 和偏差校正：

$$u_t = \max(\beta_2 u_{t-1}, |g_t|), \qquad \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{u_t + \epsilon}.$$

Adam 与 Adamax 使用 $\beta_1 = 0.9$、$\beta_2 = 0.999$。Adagrad、Adam 和 Adamax 使用 $\epsilon = 10^{-8}$。

A.3 评估指标与训练记录

预测类别为 $\hat{y}_i = \operatorname{argmax}_k p_{ik}$。混淆矩阵元素 C_{ij} 统计真实类别为 i、预测类别为 j 的样本数。准确率为 $\operatorname{tr}(C) / \sum_{ij} C_{ij}$。每类指标采用以下定义：

$$P_k = \frac{C_{kk}}{\sum_i C_{ik}}, \qquad R_k = \frac{C_{kk}}{\sum_j C_{kj}}, \qquad F1_k = \frac{2 P_k R_k}{P_k + R_k}.$$

分母为 0 时，对应指标取 0。宏平均 F1 为 10 个类别 F1 的算术平均。平均最高类别概率为 $N^{-1} \sum_i \max_k p_{ik}$。跨种子标准差采用分母 $n-1$，本实验 $n = 3$。

训练记录字段	含义
`epoch`	已完成的训练轮数
`online_objective`	本轮更新过程中的目标函数，按样本数加权
`train_loss` / `validation_loss`	轮末固定参数下的训练集与验证集数据损失
`train_cross_entropy` / `validation_cross_entropy`	轮末硬标签交叉熵
`train_accuracy` / `validation_accuracy`	轮末分类准确率
`elapsed_seconds`	本轮评估结束时的累计耗时

在线目标函数包含数据损失和 L2 惩罚。Dropout 配置的在线目标函数使用训练模式下的随机掩码。轮末数据损失使用对应配置的损失函数与标签平滑设置。轮末评估关闭 Dropout，数据损失单独统计数据项。累计耗时采样于当轮模型保存和历史记录写入之前。单次实验总耗时还包含最后一轮的文件写入。

附录 B. 学习率搜索与逐次结果

B.1 学习率搜索曲线

每行对应一种优化器，两条曲线对应两个学习率候选。左列为验证准确率，右列为验证集硬标签交叉熵。全部搜索使用种子 42，每个候选训练 3 轮。

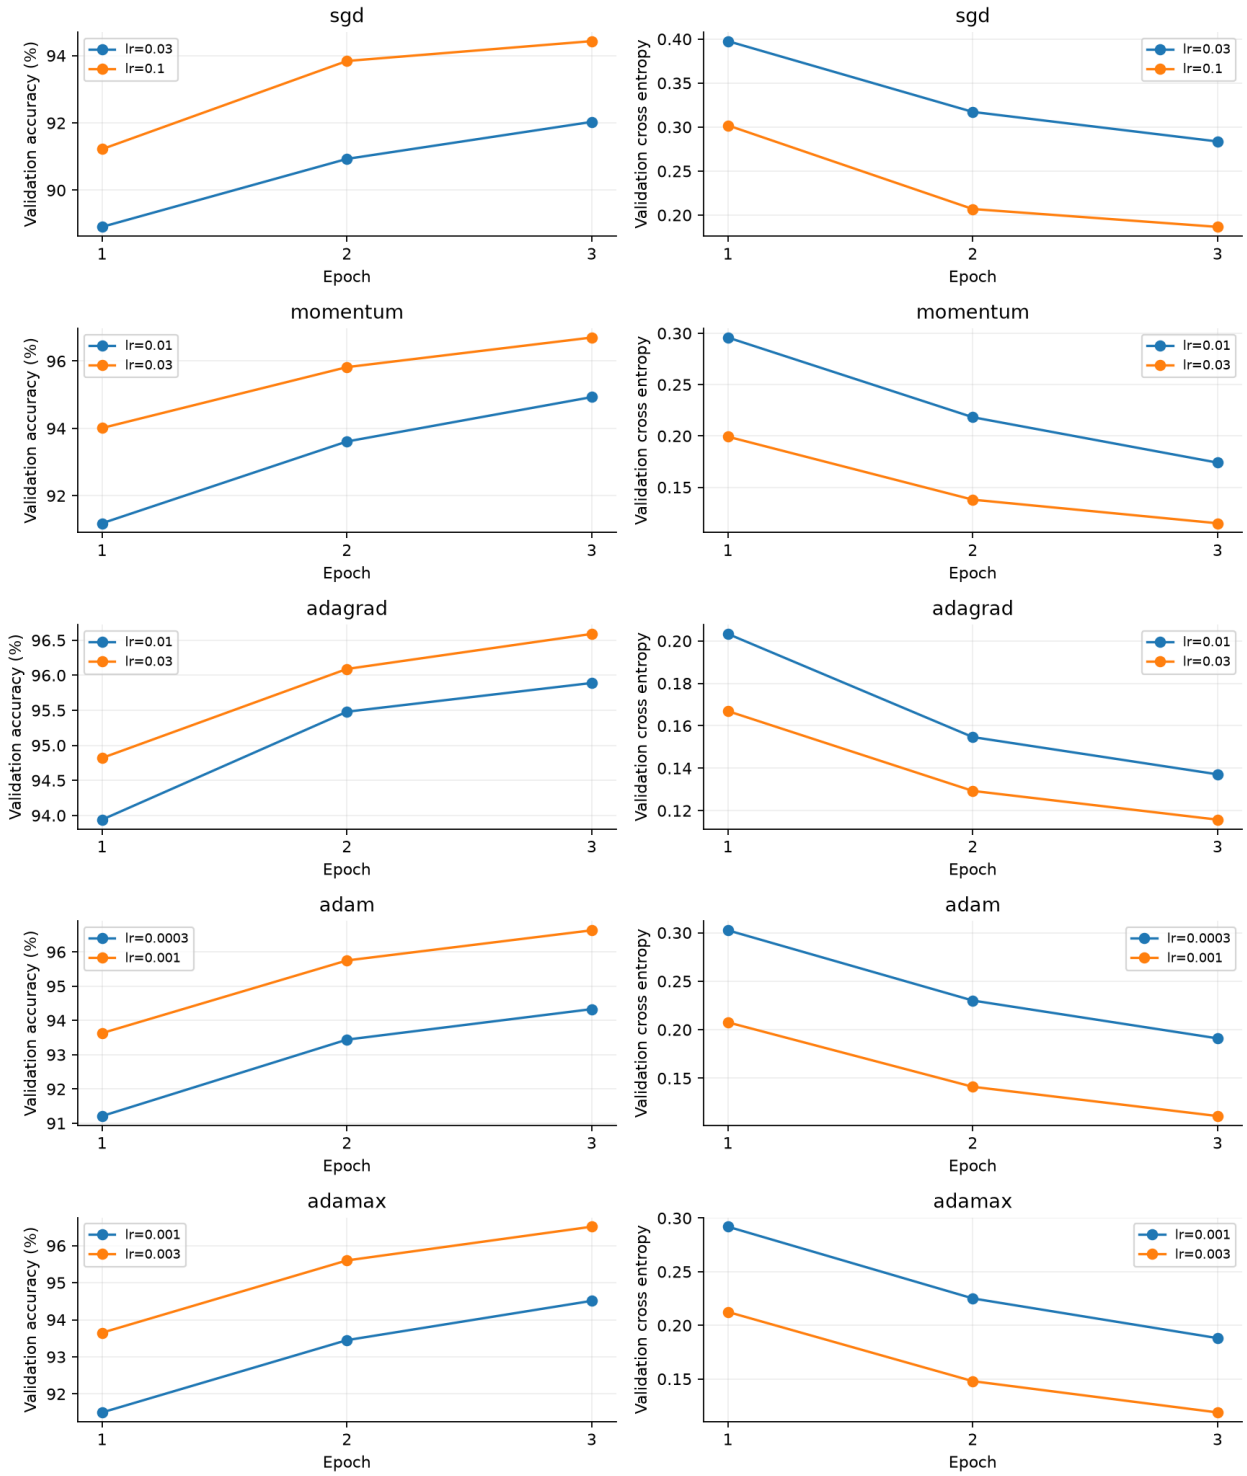


图 6: 10 次学习率搜索的完整验证曲线

B.2 搜索结果明细

训练与验证准确率采用所选轮次的数值。时间覆盖候选的全部 3 轮训练。准确率单位为百分比，时间单位为秒。

优化器	学习率	最佳轮次	训练准确率	验证准确率	验证交叉熵	时间
sgd	0.03	3	92.38	92.03	0.2837	0.700
sgd	0.1	3	95.42	94.43	0.1866	0.621
momentum	0.01	3	95.65	94.93	0.1740	0.651
momentum	0.03	3	97.76	96.70	0.1149	0.663
adagrad	0.01	3	96.89	95.89	0.1371	0.713
adagrad	0.03	3	97.68	96.59	0.1157	0.764
adam	0.0003	3	95.08	94.33	0.1911	0.886
adam	0.001	3	97.77	96.63	0.1110	0.853
adamax	0.001	3	95.19	94.51	0.1880	0.830
adamax	0.003	3	97.44	96.51	0.1187	0.810

学习率搜索总耗时为 7.491 秒。

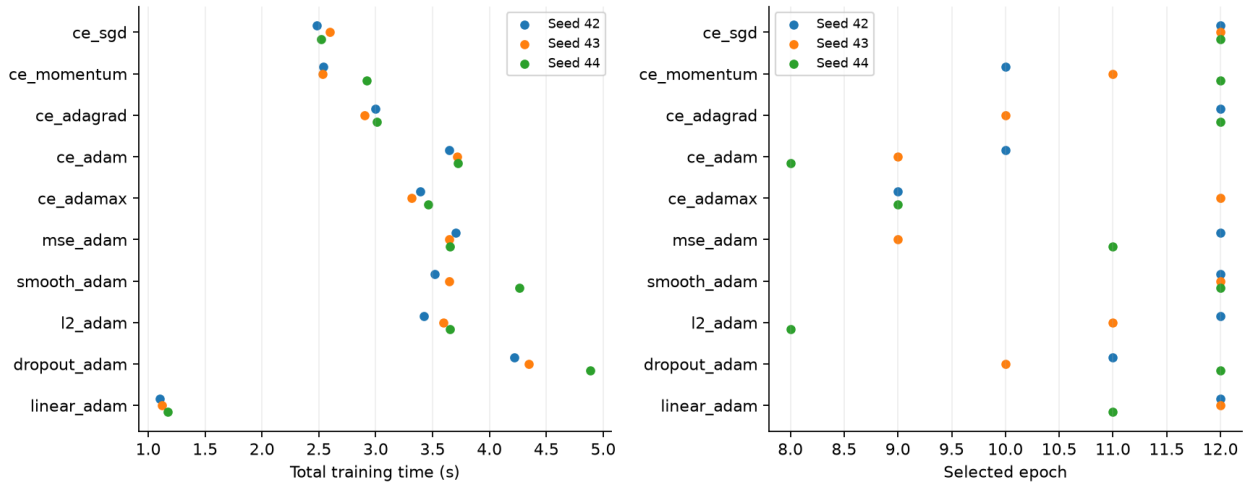


图 7: 30 次正式实验的耗时与最佳轮次

每个点对应一次运行，颜色区分训练种子。

B.3 全部 30 次运行的分类指标

每行对应一次正式训练及所选模型的测试结果。训练与验证指标均取最佳轮次。准确率和宏平均 F1 的数值均乘以 100。

配置	种子	最佳轮次	训练准确率	验证准确率	测试准确率	宏平均 F1
ce_sgd	42	12	98.80	97.12	97.52	97.51
ce_sgd	43	12	98.77	97.11	97.29	97.27
ce_sgd	44	12	98.83	97.17	97.35	97.32
ce_momentum	42	10	99.58	97.58	97.76	97.74
ce_momentum	43	11	99.71	97.72	97.83	97.81
ce_momentum	44	12	99.72	97.61	97.78	97.76
ce_adagrad	42	12	99.57	97.52	97.70	97.67
ce_adagrad	43	10	99.53	97.58	97.49	97.47
ce_adagrad	44	12	99.69	97.53	97.73	97.71
ce_adam	42	10	99.52	97.59	97.73	97.71
ce_adam	43	9	99.54	97.65	97.84	97.82
ce_adam	44	8	99.31	97.42	97.59	97.58
ce_adamax	42	9	99.25	97.76	97.61	97.59
ce_adamax	43	12	99.75	97.56	97.80	97.78
ce_adamax	44	9	99.36	97.50	97.69	97.67
mse_adam	42	12	99.43	97.65	97.97	97.95
mse_adam	43	9	98.98	97.34	97.45	97.44
mse_adam	44	11	99.31	97.45	97.55	97.53
smooth_adam	42	12	99.83	98.14	98.15	98.13
smooth_adam	43	12	99.83	97.90	97.92	97.90
smooth_adam	44	12	99.81	98.09	98.00	97.99
l2_adam	42	12	99.57	97.79	97.85	97.84
l2_adam	43	11	99.62	97.69	98.03	98.02
l2_adam	44	8	99.31	97.56	97.69	97.68
dropout_adam	42	11	99.23	97.56	97.75	97.73
dropout_adam	43	10	99.15	97.69	97.74	97.73
dropout_adam	44	12	99.36	97.79	97.83	97.82
linear_adam	42	12	93.00	92.05	92.61	92.50
linear_adam	43	12	92.95	91.97	92.49	92.38
linear_adam	44	11	92.93	92.05	92.60	92.48

B.4 全部 30 次运行的损失、置信度与耗时

验证交叉熵和测试交叉熵均采用硬标签。置信度列为测试集平均最高类别概率，单位为百分比。时间列为单次训练总耗时，单位为秒。

配置	种子	验证交叉熵	测试交叉熵	置信度	时间
ce_sgd	42	0.09595	0.08004	97.52	2.484
ce_sgd	43	0.09795	0.08520	97.27	2.594
ce_sgd	44	0.09640	0.08549	97.51	2.519
ce_momentum	42	0.09295	0.07562	98.43	2.540
ce_momentum	43	0.08659	0.07508	98.61	2.534
ce_momentum	44	0.09113	0.07601	98.70	2.918
ce_adagrad	42	0.08758	0.07762	98.24	2.998
ce_adagrad	43	0.08969	0.08030	98.24	2.904
ce_adagrad	44	0.08562	0.07578	98.37	3.012
ce_adam	42	0.08902	0.07772	98.35	3.647
ce_adam	43	0.08366	0.07571	98.48	3.714
ce_adam	44	0.08672	0.07838	98.10	3.719
ce_adamax	42	0.08259	0.07790	98.09	3.393
ce_adamax	43	0.08653	0.07595	98.37	3.313
ce_adamax	44	0.08482	0.07793	98.05	3.463
mse_adam	42	0.08289	0.07632	98.23	3.706
mse_adam	43	0.09209	0.09132	97.83	3.648
mse_adam	44	0.09239	0.08411	98.24	3.650
smooth_adam	42	0.16874	0.16491	87.58	3.516
smooth_adam	43	0.16145	0.15989	88.34	3.647
smooth_adam	44	0.16830	0.16592	87.55	4.265
l2_adam	42	0.08131	0.07583	98.46	3.424
l2_adam	43	0.08326	0.07015	98.49	3.596
l2_adam	44	0.08497	0.07369	97.91	3.650
dropout_adam	42	0.08294	0.07741	98.29	4.216
dropout_adam	43	0.08112	0.08015	98.27	4.345
dropout_adam	44	0.07950	0.07821	98.53	4.885
linear_adam	42	0.28160	0.26555	90.90	1.103
linear_adam	43	0.28336	0.26578	90.85	1.120
linear_adam	44	0.28493	0.26658	90.75	1.170

附录 C. 各配置完整训练曲线与混淆矩阵

每种配置分别展示种子 42、43、44 的 12 轮训练记录。曲线颜色区分种子，实线与虚线区分训练集和验证集。各图完整覆盖训练历史中的 9 个字段。最后一个面板由训练准确率减去验证准确率得到。

混淆矩阵使用各次运行选定的最佳模型。矩阵行表示真实类别，列表示预测类别，单元格表示样本数。每个矩阵共统计 10,000 张测试图像。

C.1 ce_sgd

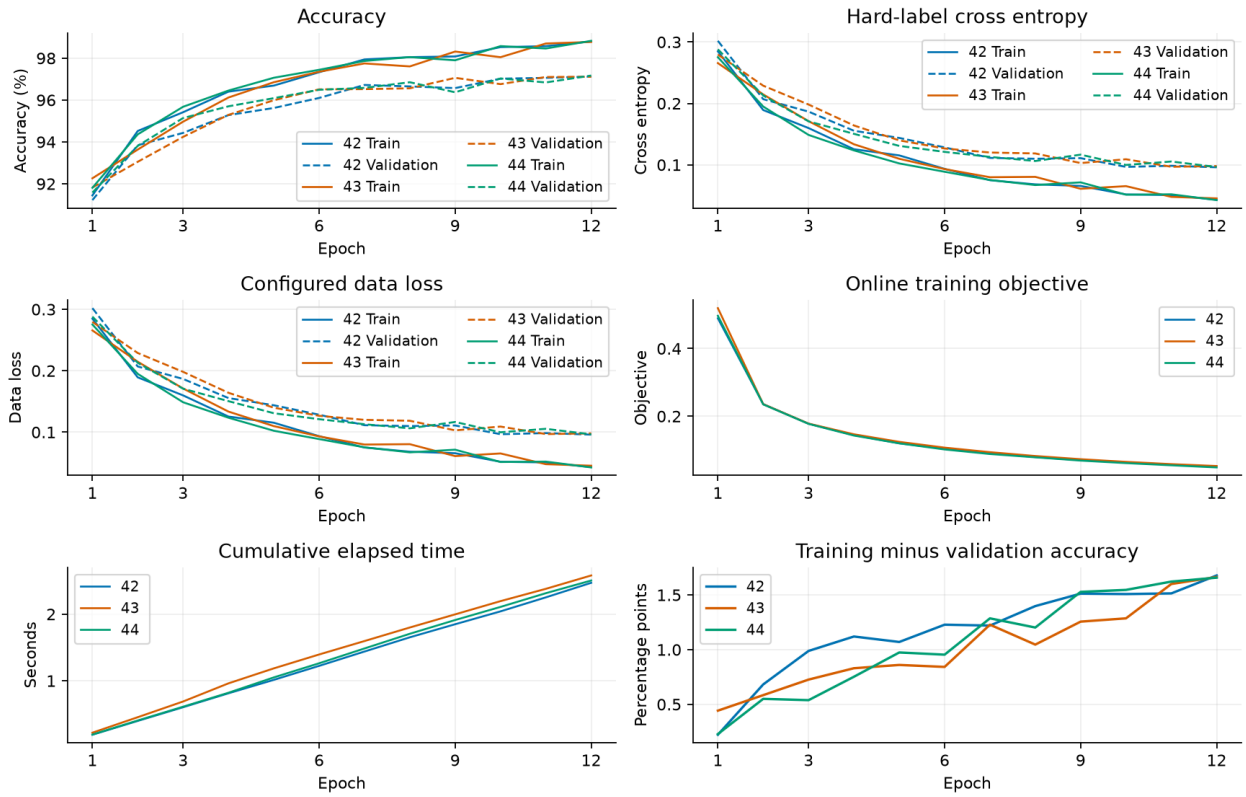


图 8: ce_sgd 在 3 个种子下的完整训练曲线

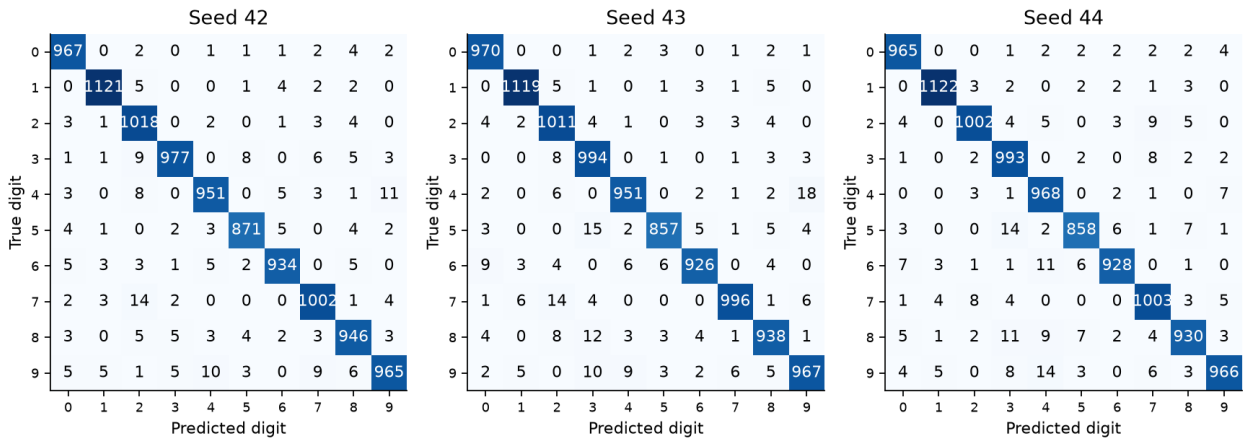


图 9: ce_sgd 在 3 个种子下的测试混淆矩阵

C.2 ce_momentum

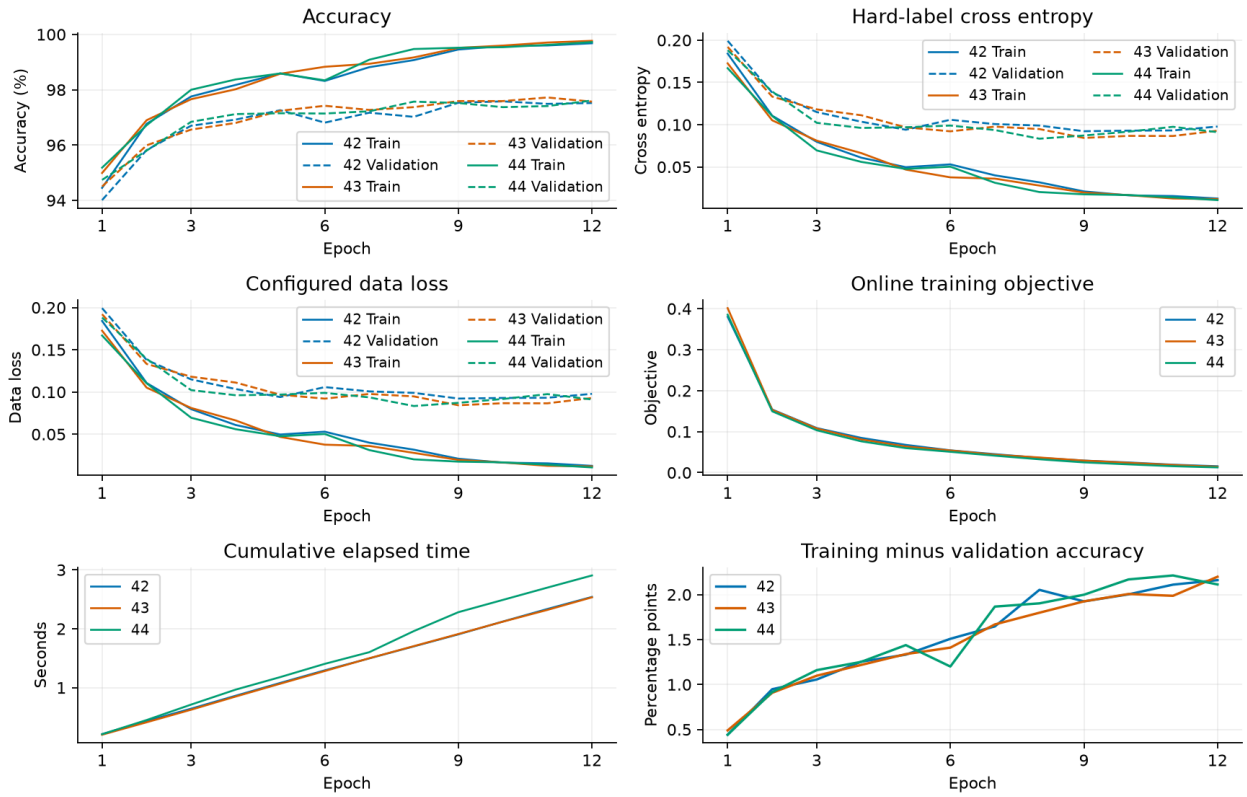


图 10: ce_momentum 在 3 个种子下的完整训练曲线

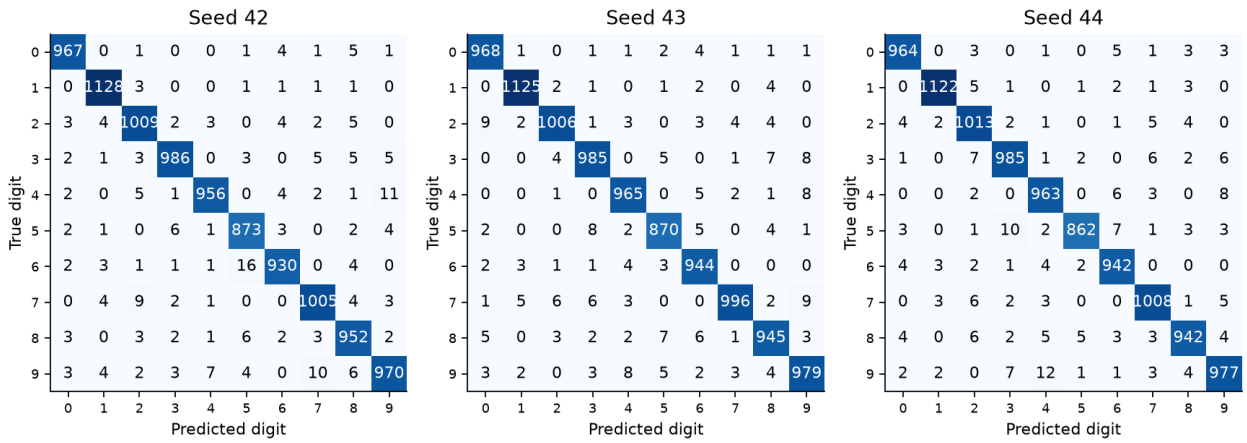


图 11: ce_momentum 在 3 个种子下的测试混淆矩阵

C.3 ce_adagrad

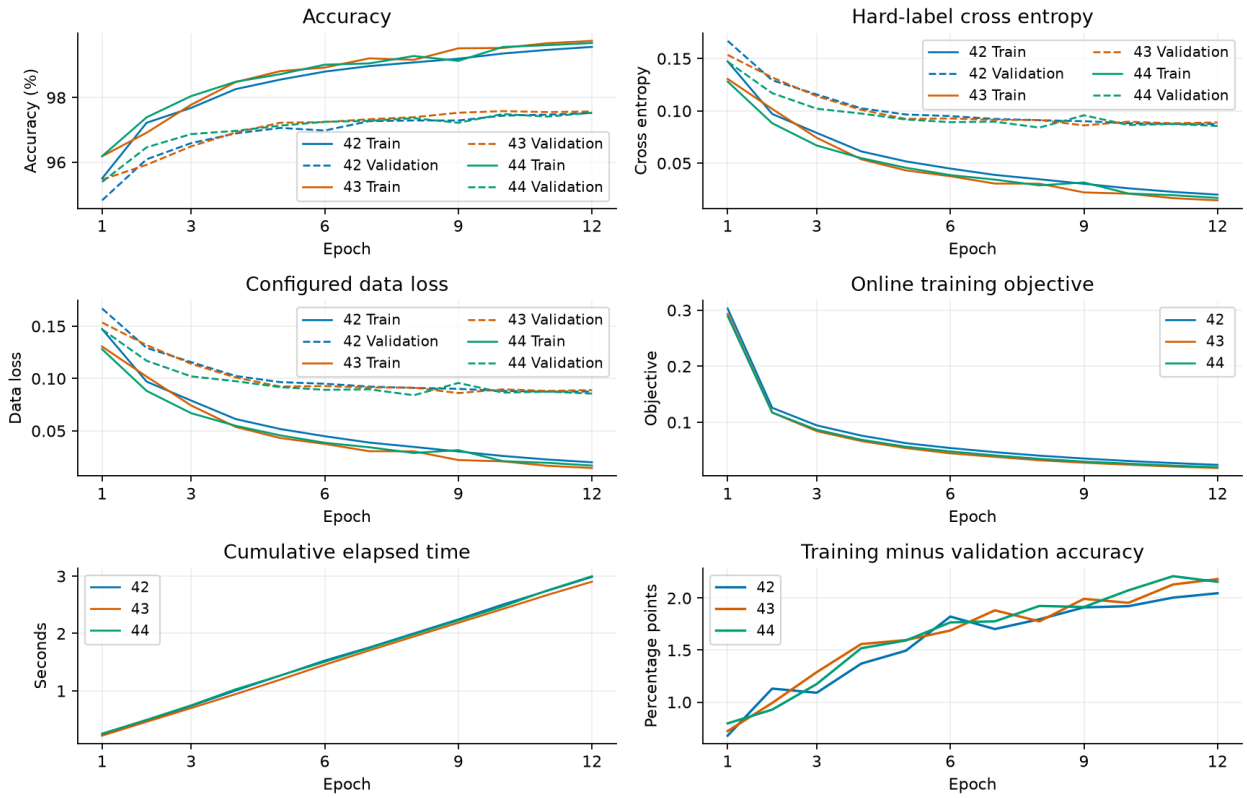


图 12: ce_adagrad 在 3 个种子下的完整训练曲线

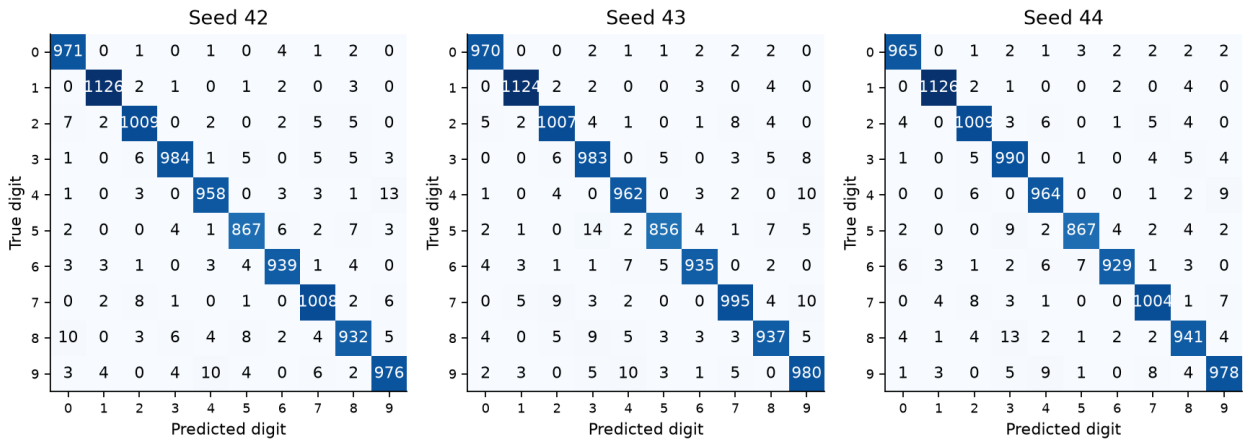


图 13: ce_adagrad 在 3 个种子下的测试混淆矩阵

C.4 ce_adam

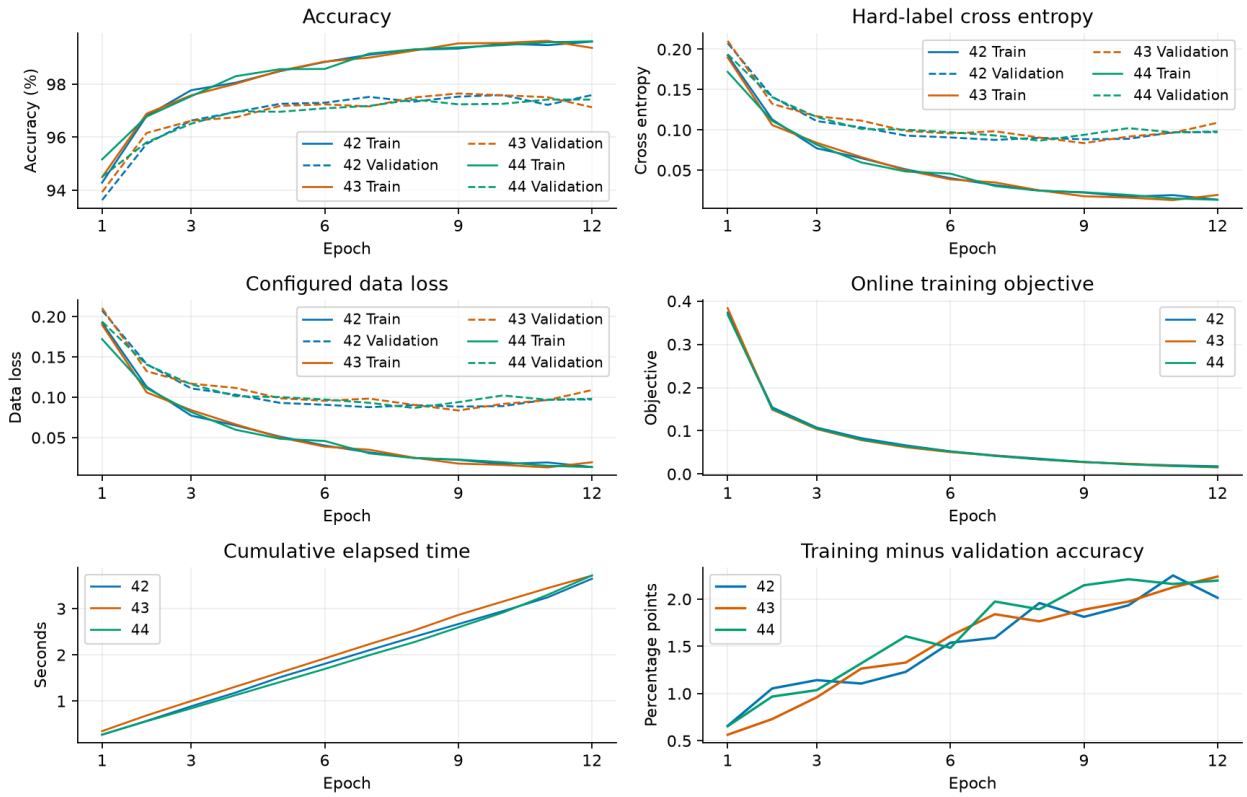


图 14: ce_adam 在 3 个种子下的完整训练曲线

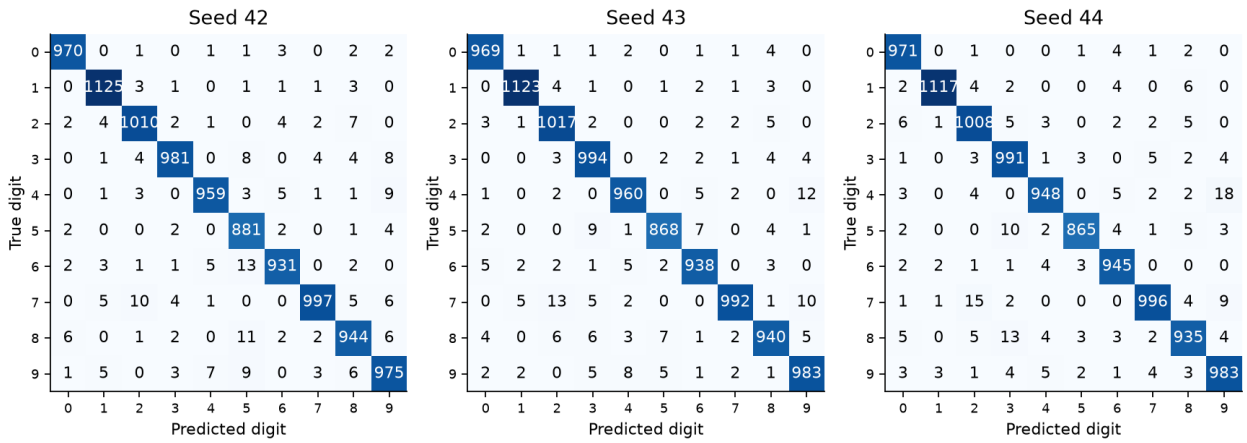


图 15: ce_adam 在 3 个种子下的测试混淆矩阵

C.5 ce_adamax

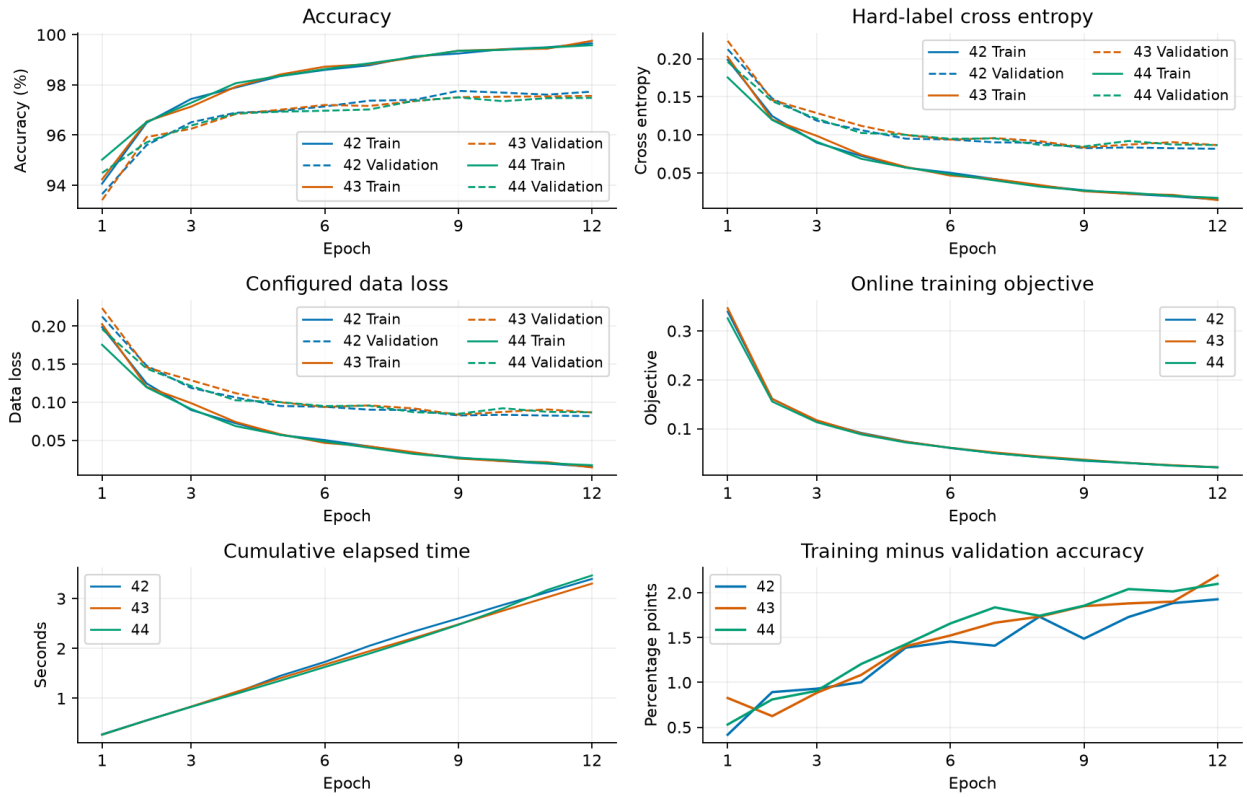


图 16: ce_adamax 在 3 个种子下的完整训练曲线

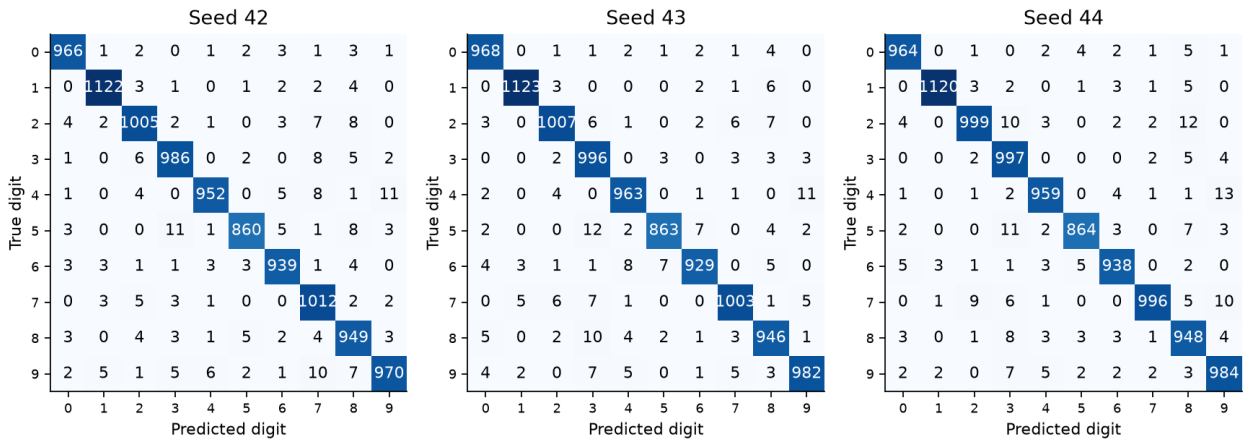


图 17: ce_adamax 在 3 个种子下的测试混淆矩阵

C.6 `mse_adam`

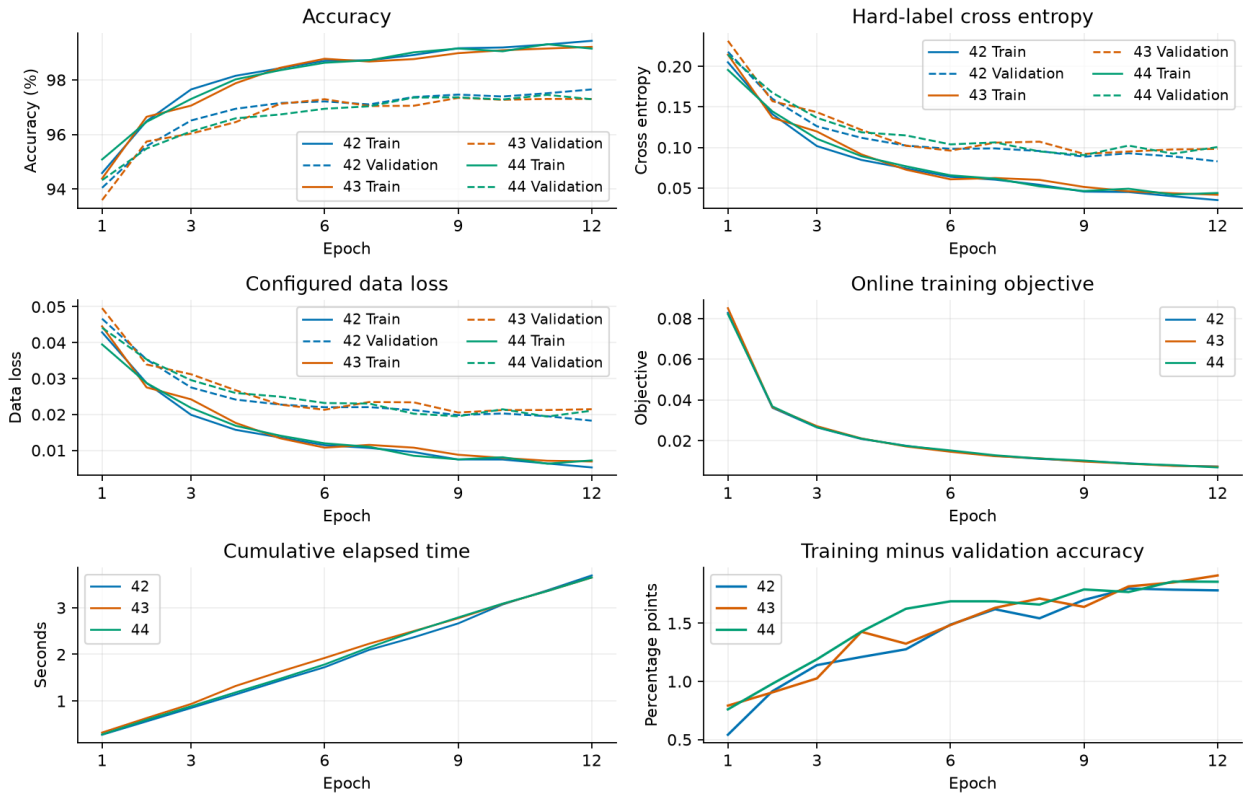


图 18: mse_adam 在 3 个种子下的完整训练曲线

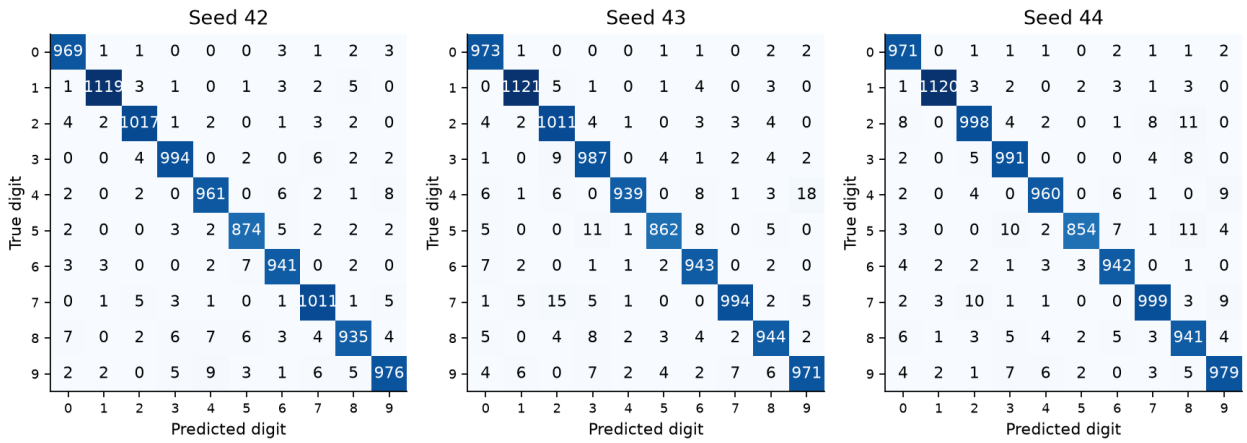


图 19: mse_adam 在 3 个种子下的测试混淆矩阵

C.7 `smooth_adam`

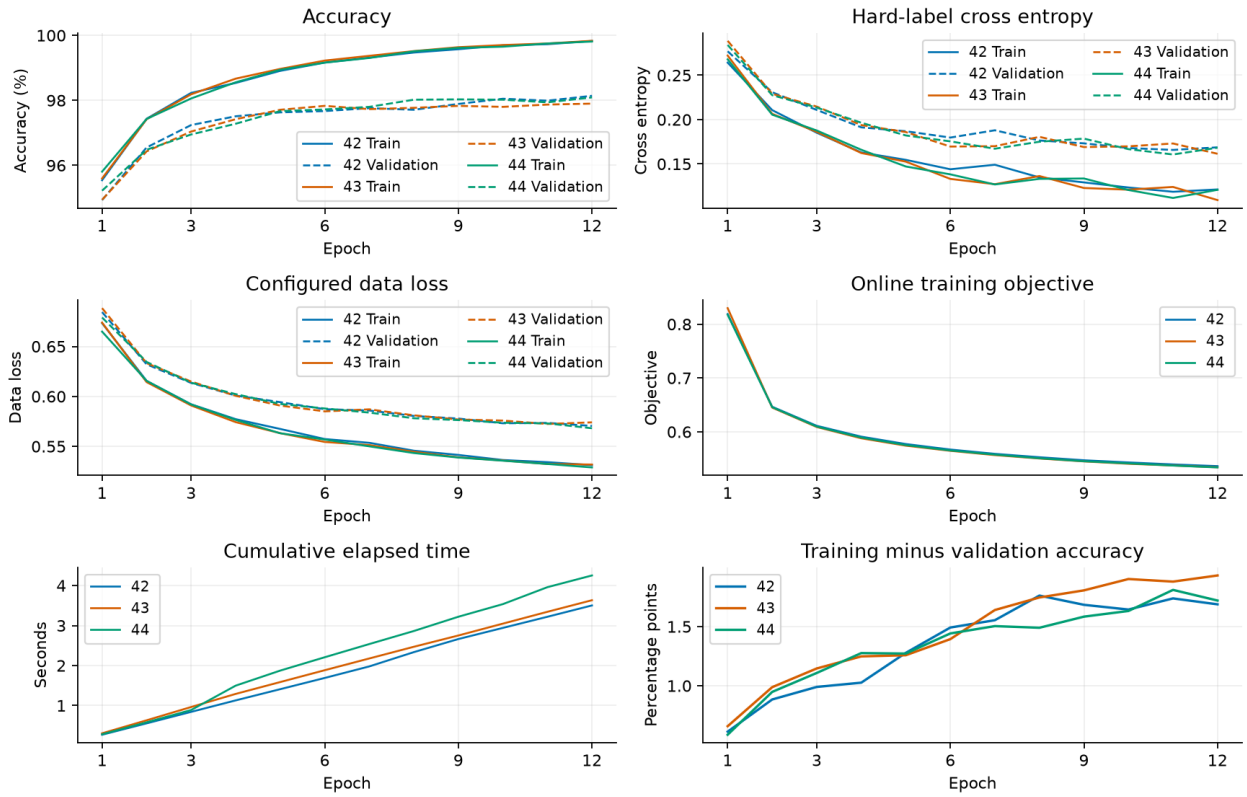


图 20: smooth_adam 在 3 个种子下的完整训练曲线

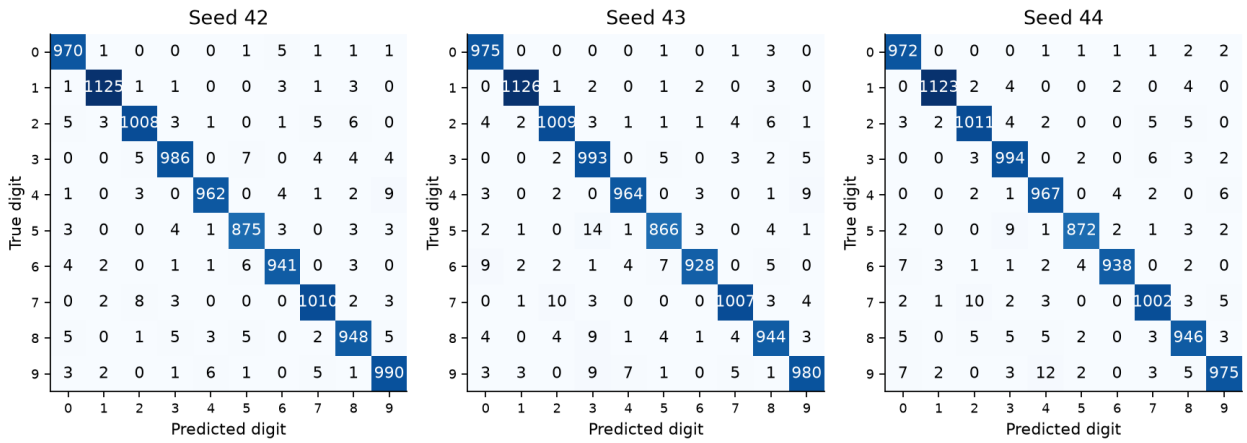


图 21: smooth_adam 在 3 个种子下的测试混淆矩阵

C.8 l2_adam

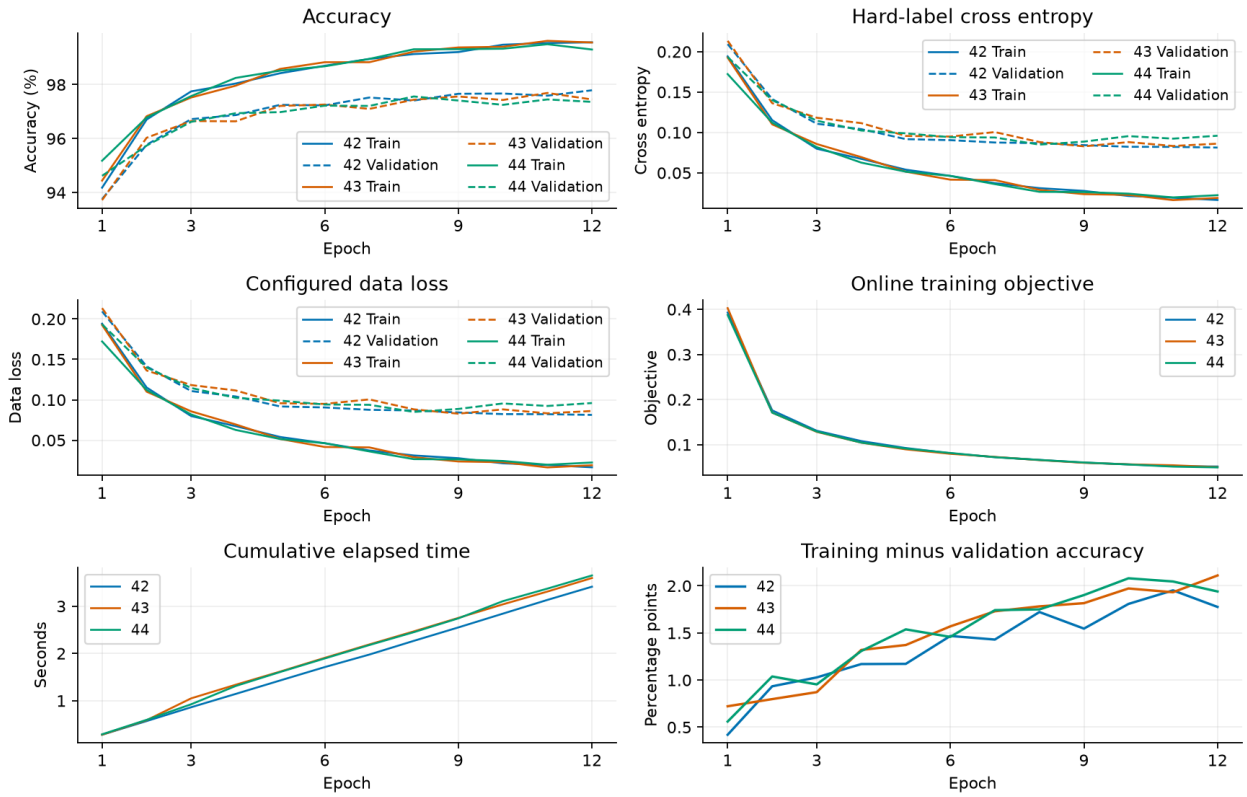


图 22: l2_adam 在 3 个种子下的完整训练曲线

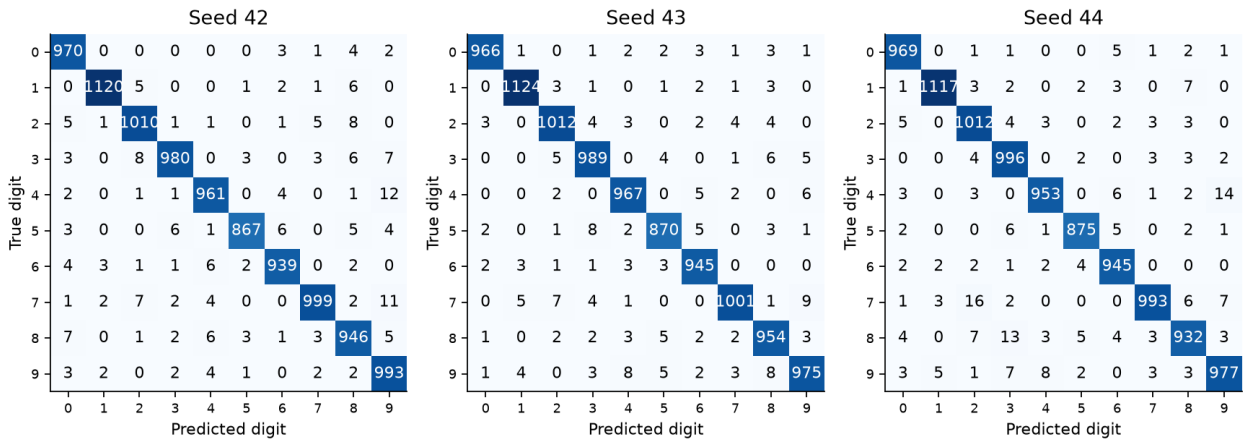


图 23: l2_adam 在 3 个种子下的测试混淆矩阵

C.9 `dropout_adam`

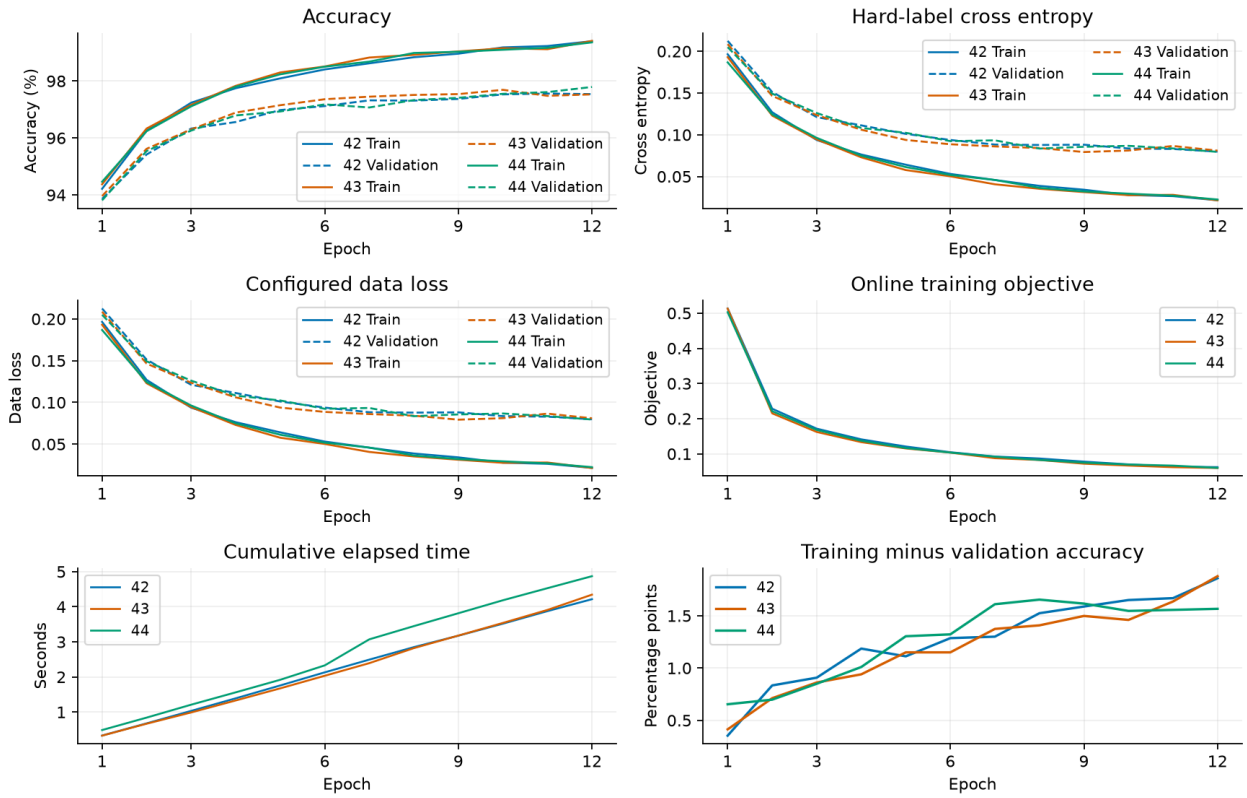


图 24: dropout_adam 在 3 个种子下的完整训练曲线

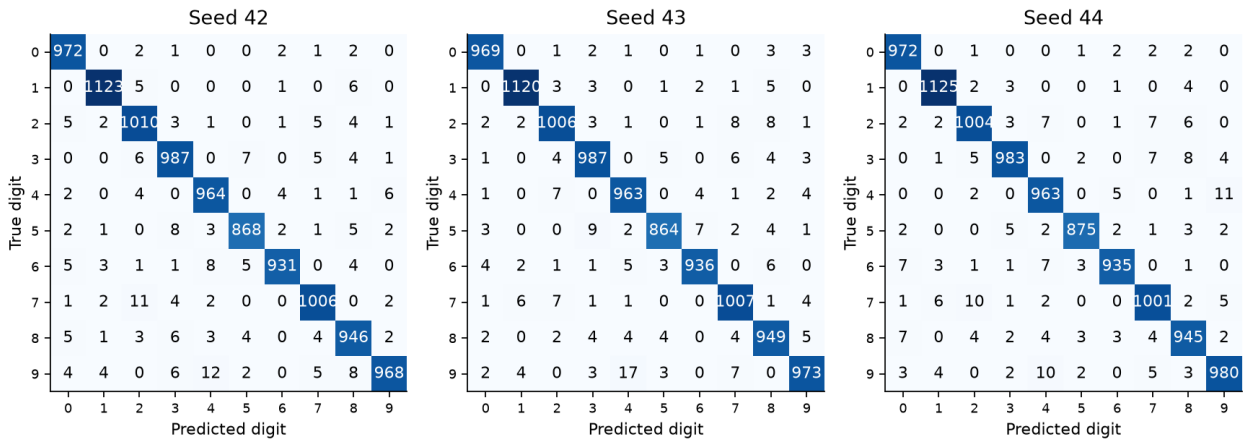


图 25: dropout_adam 在 3 个种子下的测试混淆矩阵

C.10 `linear_adam`

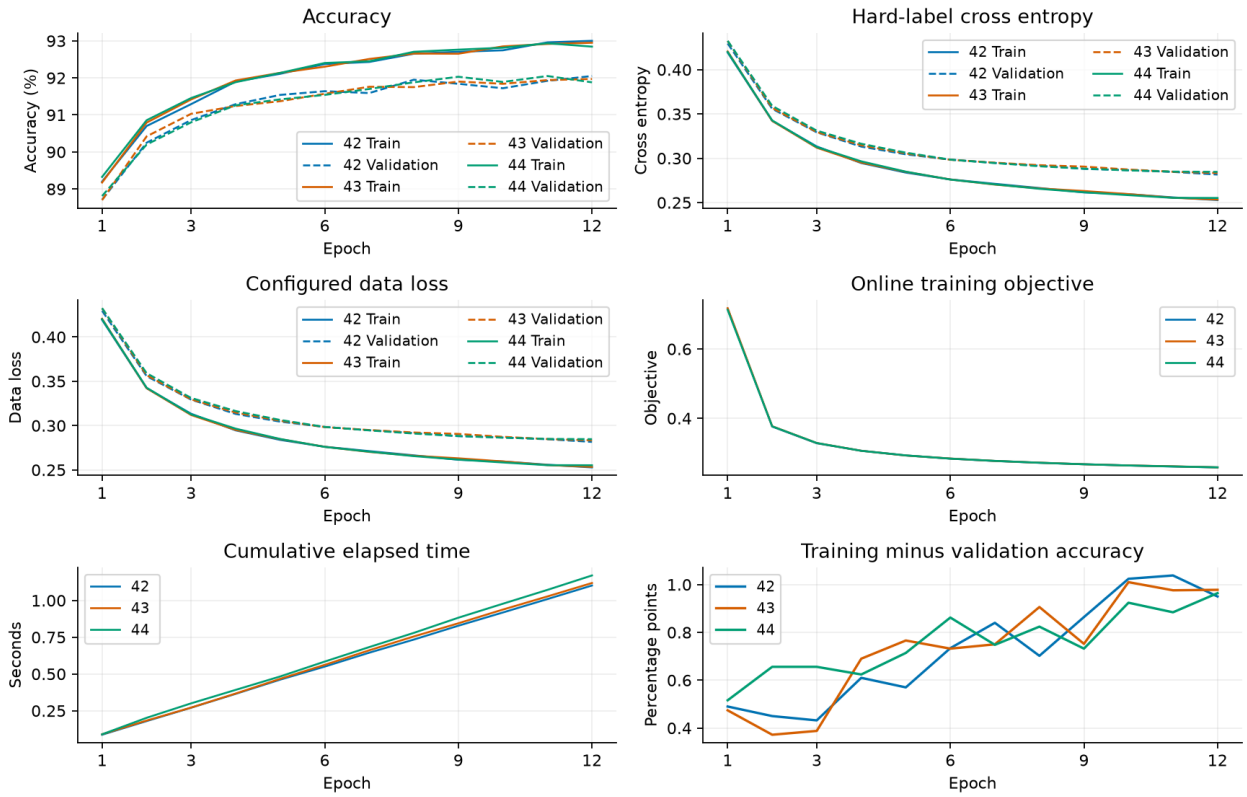


图 26: linear_adam 在 3 个种子下的完整训练曲线

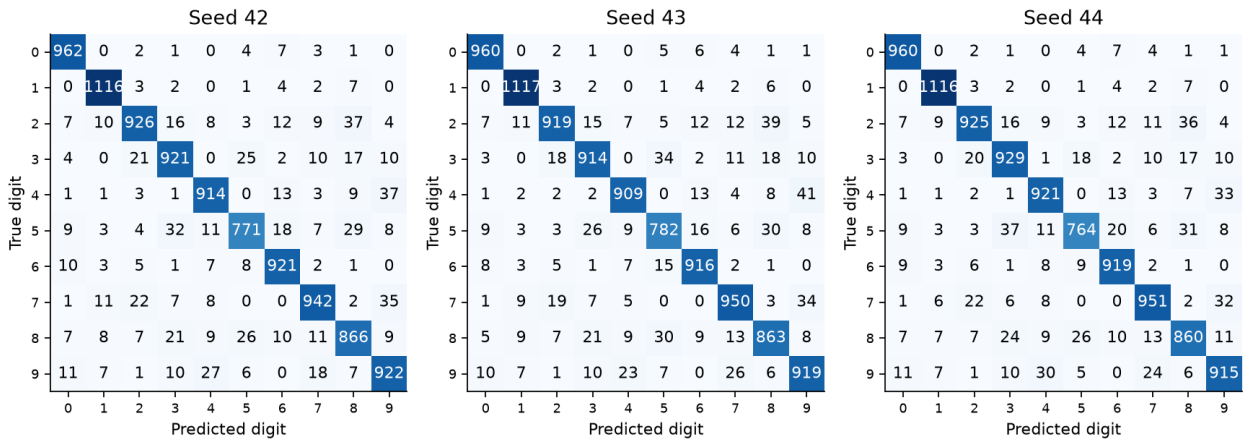


图 27: linear_adam 在 3 个种子下的测试混淆矩阵

附录 D. 全部模型的逐类指标

D.1 各类别精确率

每行对应一种配置与一个种子，每列对应数字 0 至 9。单元格数值为百分比，保留两位小数。

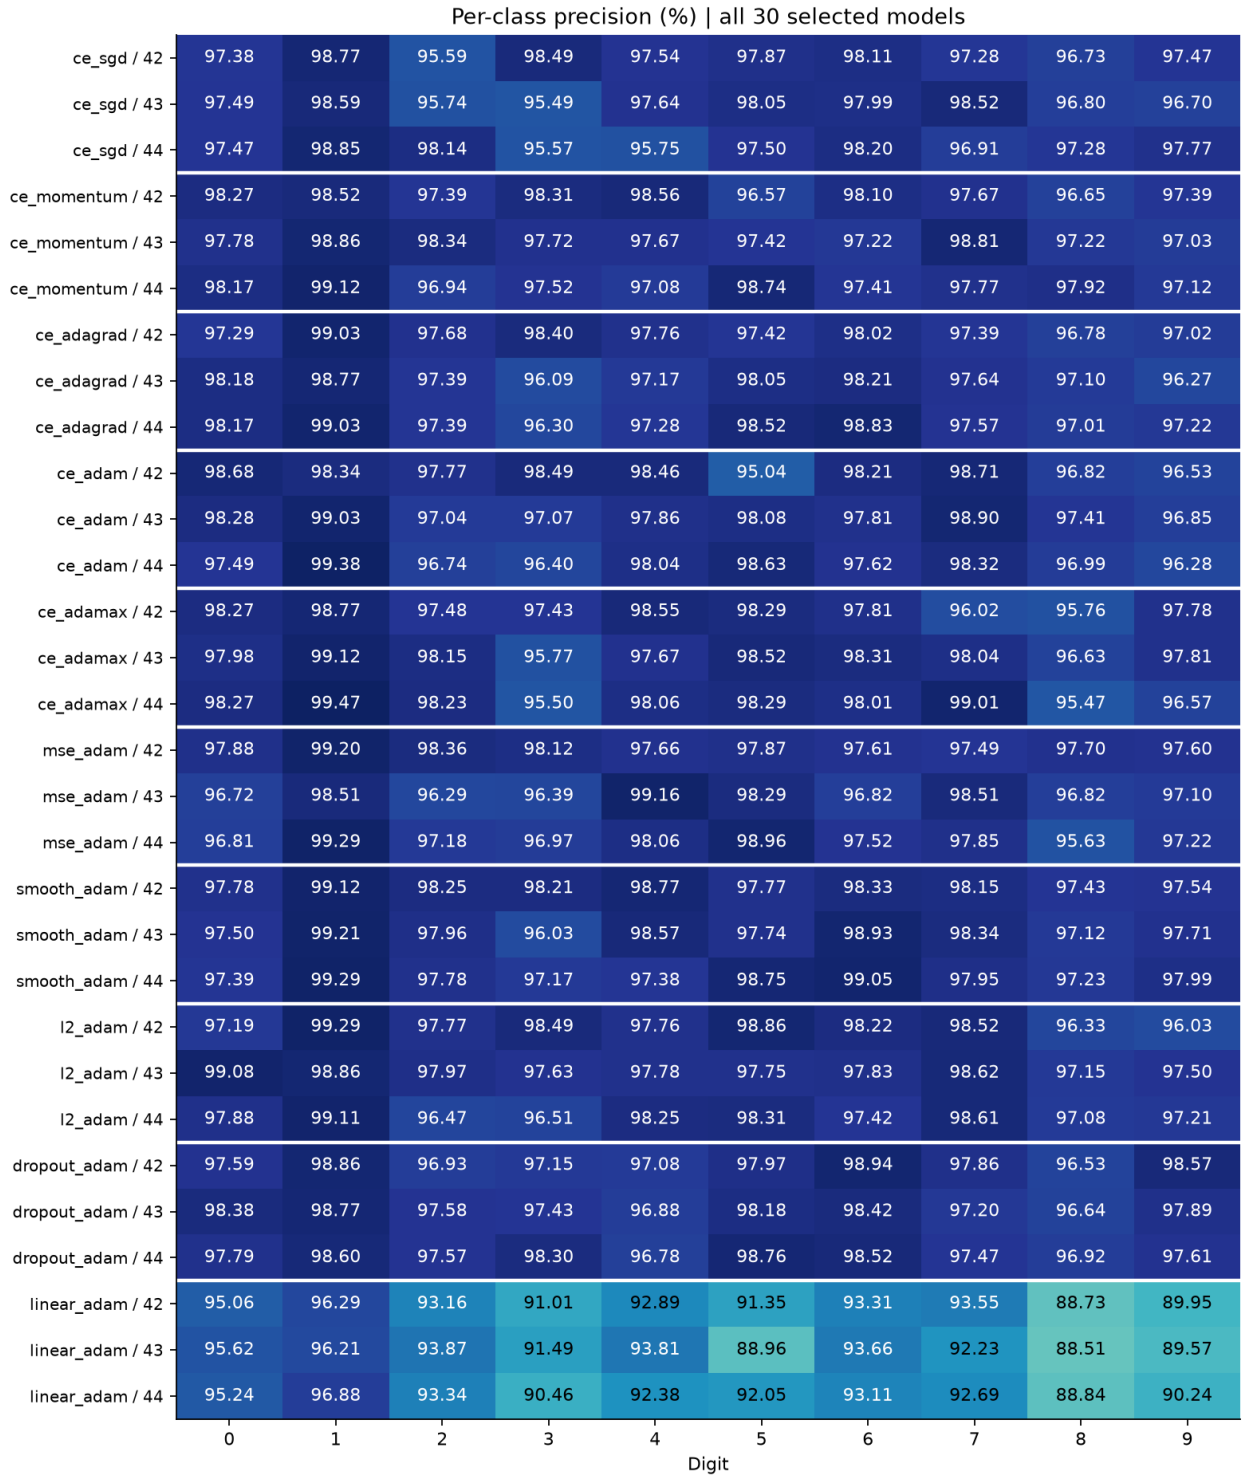


图 28: 全部 30 个模型的逐类精确率

D.2 各类别召回率

每行对应一种配置与一个种子，每列对应数字 0 至 9。单元格数值为百分比，保留两位小数。

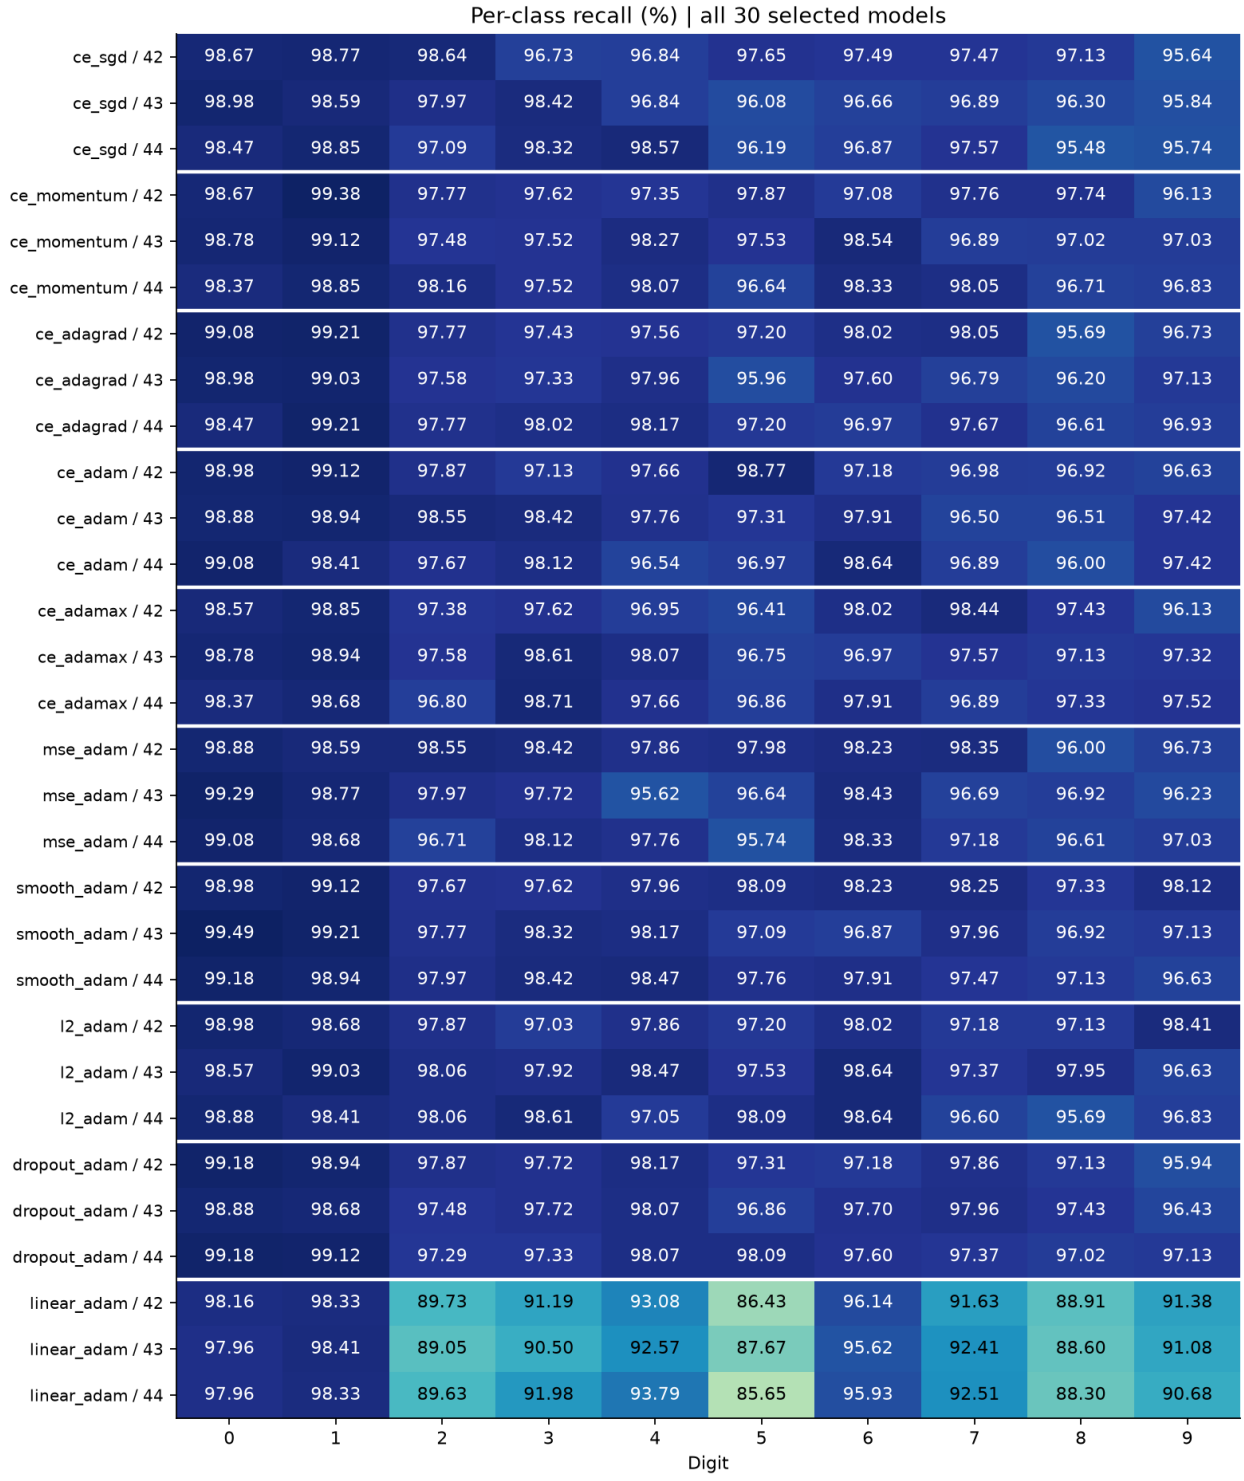


图 29: 全部 30 个模型的逐类召回率

D.3 各类别 F1

每行对应一种配置与一个种子，每列对应数字 0 至 9。单元格数值为百分比，保留两位小数。

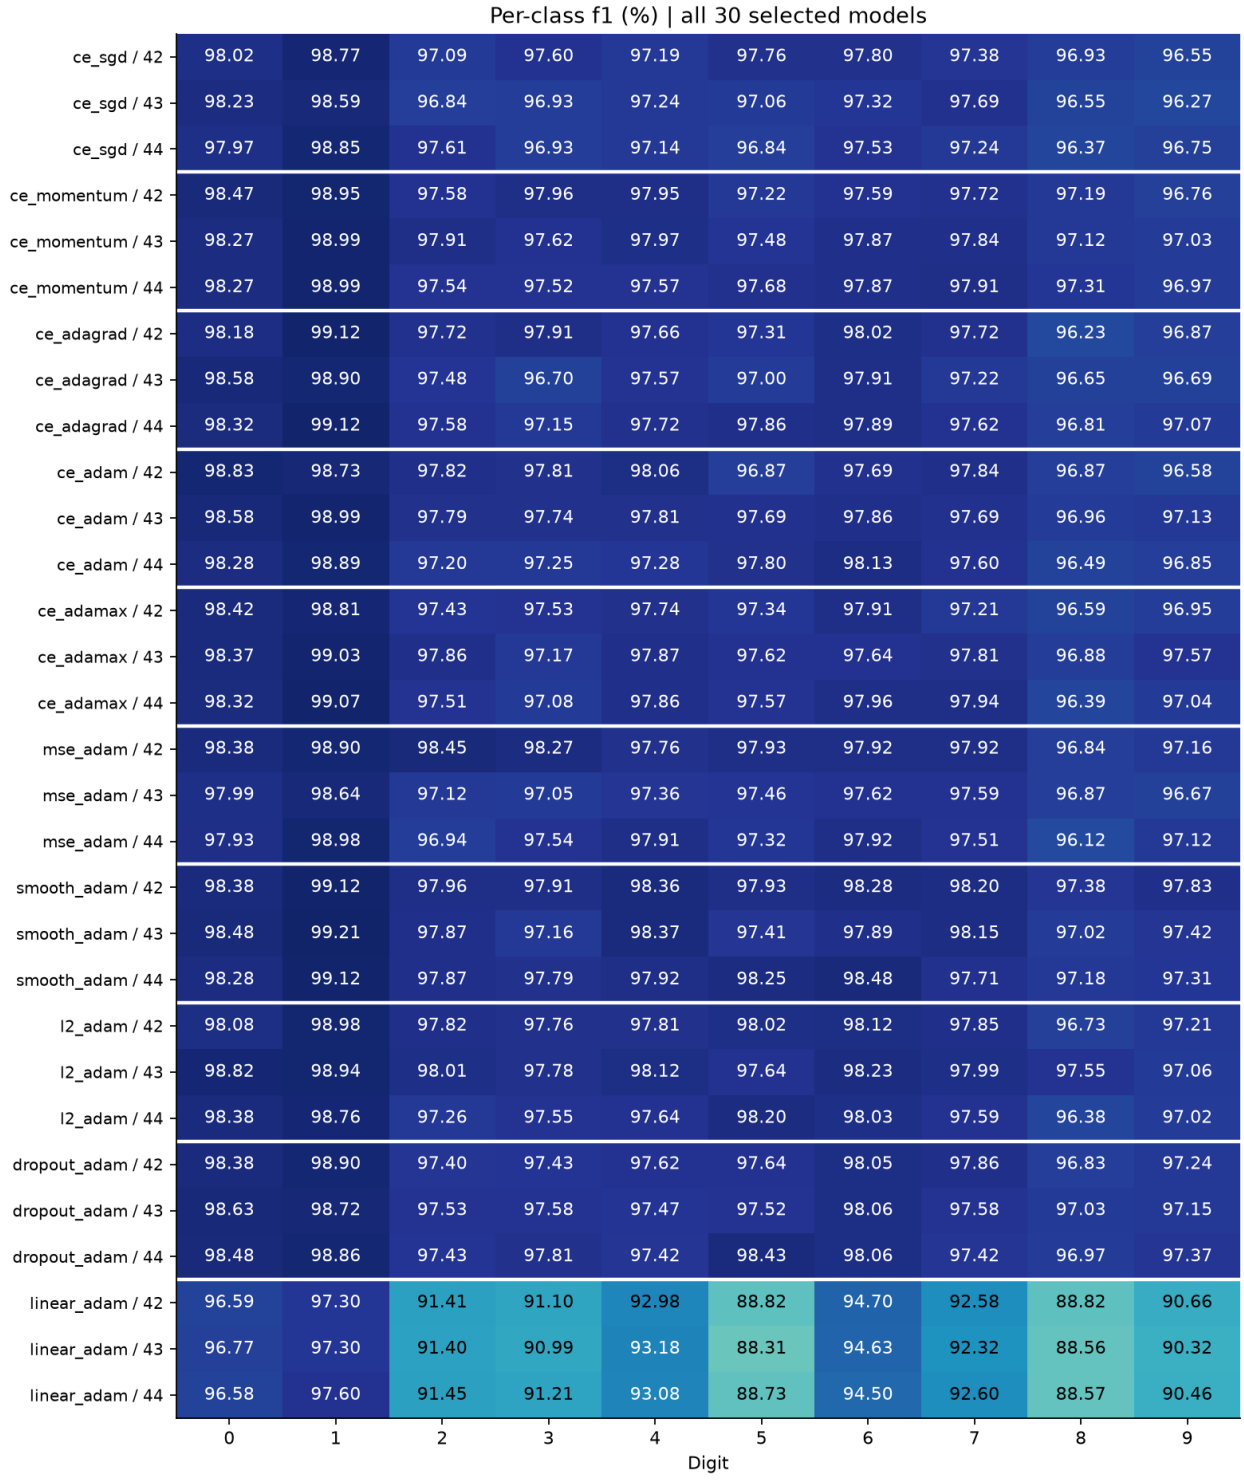


图 30: 全部 30 个模型的逐类 F1

D.4 最终模型的归一化混淆矩阵

每行以该真实类别的样本数为分母，数值单位为百分比。对角线数值对应逐类召回率。

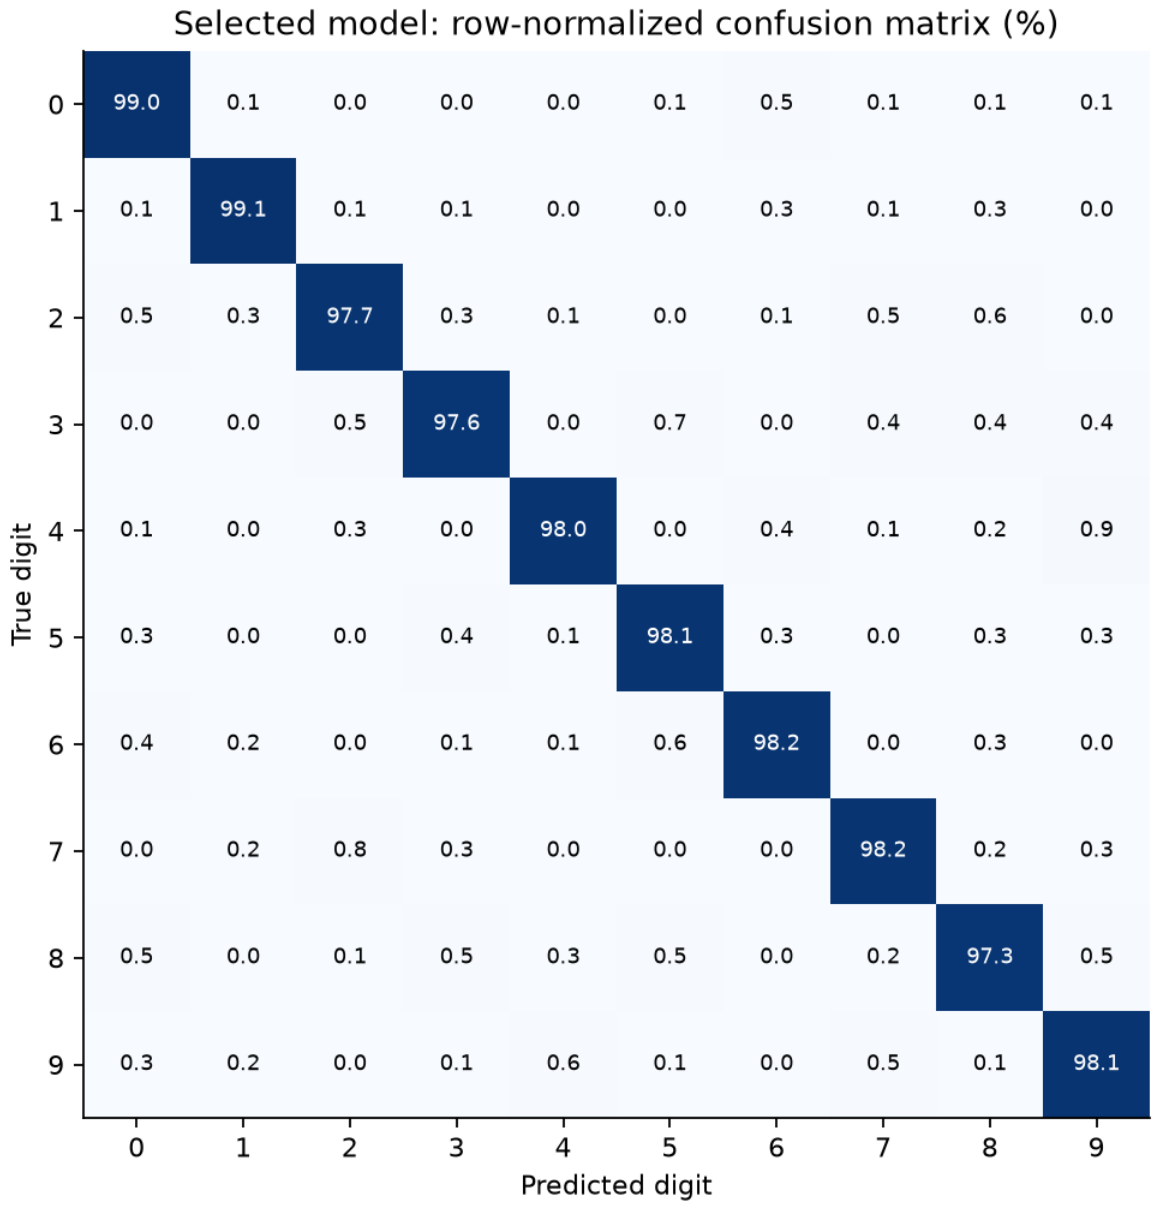


图 31: 最终模型的逐行归一化混淆矩阵

最终模型正确分类 9,815 张图像，误分类 185 张图像。

附录 E. 实现流程、验证记录与复现

E.1 训练与模型选择流程

读取原始训练集，按固定种子分层划分训练集与验证集
对每种优化器：
    对两个候选学习率分别训练 3 轮
    依据最佳验证准确率选择学习率
对每种正式配置和每个训练种子：
    初始化网络、优化器、批次排列与 Dropout 随机数流
    重复 12 轮：
        打乱训练索引，依次取出小批次
        前向传播 -> 计算损失 -> 反向传播 -> 更新参数
        评估完整训练集与验证集，记录本轮历史
        按验证准确率与交叉熵保存最佳模型
汇总各配置的平均验证准确率，选择最终配置
固定种子 42 的模型，保存模型选择结果
加载测试集，评估已确定的模型，保存评估指标

初始化随机种子为训练种子。批次排列随机种子为训练种子加 1,000。Dropout 随机种子为训练种子加 2,000。三个随机数流分别控制初始化、样本顺序和随机掩码。

E.2 正确性检查

检查项目	检查内容与结果
自动测试	18 项测试通过
数值梯度	中心差分核对交叉熵、MSE、平滑、L2、Dropout
Softmax	极端输入下的数值稳定性与平移不变性
优化器	5 种算法的两步参数更新符合手算结果
数据划分	训练与验证索引互斥、完整、可复现
指标	混淆矩阵、零预测类别、末尾短批次加权通过
模型恢复	保存后加载的预测一致，单样本推理通过
训练流程	合成数据分类学习通过
正式结果	30 次运行的最佳轮次和混淆矩阵核对通过
确定性复现	smooth_adam、种子 42 的重训参数逐项一致
命令行推理	8 张训练图像的预测核对通过

E.3 运行环境与命令

训练环境为 `macOS-15.2-arm64-arm-64bit`。Python 版本为 `3.11.14`，NumPy 版本为 `2.4.6`。

项目使用 uv 管理 Python 环境，依赖版本固定在 `uv.lock`。实验使用 CPU，三个线程环境变量均设置为 1。项目目录包含数据文件、实验配置、源码和实验记录。前置条件为已安装 uv，首次同步依赖需要联网。

1. 进入项目目录。

   ```
   cd A1_submission
   ```

2. 同步依赖。

   ```
   uv sync --managed-python --locked
   ```

3. 运行正确性测试。

   ```
   uv run --managed-python pytest -q
   ```

4. 读取完整结果或继续中断的实验流程。

   ```
   OPENBLAS_NUM_THREADS=1 VECLIB_MAXIMUM_THREADS=1 OMP_NUM_THREADS=1 uv run --managed-python
    ↪  a1-experiment --resume
   ```

全量复跑使用独立输出路径，命令如下。

```
OPENBLAS_NUM_THREADS=1 VECLIB_MAXIMUM_THREADS=1 OMP_NUM_THREADS=1 uv run --managed-python
 ↪  a1-experiment --output tmp/reproduction
```

模型推理接收 `.npy` 文件，形状为 `(N, 28, 28)` 或 `(N, 784)`。`uint8` 图像采用 0 至 255 像素值。浮点图像采用归一化后的 0 至 1 像素值。图像采用黑色背景、白色笔画。

```
uv run --managed-python a1-predict path/to/images.npy
```

PDF 导出使用 Pandoc 和 XeLaTeX。`bash scripts/export_pdf.sh` 生成 `tmp/pdfs/REPORT.pdf`。正式报告路径为 `REPORT.pdf`。